Análise da Taxa de Mortalidade Infantil e Indicadores Socioeconômicos

Adriano Porto Kauan Brito

2026-03-13

Introdução

A taxa de mortalidade infantil (TMI) é um dos principais indicadores utilizados para avaliar as condições de saúde e desenvolvimento socioeconômico de uma população. Esse indicador reflete não apenas a qualidade da assistência médica disponível, mas também aspectos estruturais da sociedade, como condições de saneamento, renda, educação e desigualdade social.

Diversos fatores socioeconômicos podem influenciar diretamente os níveis de mortalidade infantil. Entre esses fatores destacam-se o acesso ao saneamento básico, o nível de renda da população, a cobertura de serviços de atenção primária à saúde, o nível educacional da população e indicadores de desigualdade econômica.

Neste estudo busca-se analisar a relação entre a taxa de mortalidade infantil e diferentes indicadores socioeconômicos e de infraestrutura de saúde. Para isso, será utilizada uma base de dados contendo variáveis relacionadas a condições econômicas, sociais e de acesso à saúde.

O objetivo principal desta análise é investigar possíveis associações entre a taxa de mortalidade infantil e variáveis socioeconômicas, além de realizar uma análise exploratória inicial da base de dados.

Descrição da Base de Dados

A base de dados utilizada neste estudo contém informações relacionadas a indicadores socioeconômicos e de saúde pública. Cada observação corresponde a uma unidade geográfica, podendo representar estados ou municípios, contendo variáveis explicativas que podem influenciar a taxa de mortalidade infantil.

Leitura da base de dados

```r
dados <- read_excel("dados.xlsx")

dados$regiao <- factor(
  dados$regiao,
  levels = c("Norte", "Nordeste", "Centro-Oeste", "Sudeste", "Sul")
)

head(dados)
```

```
# A tibble: 6 x 11
     id   tmi saneamento pib_percapita cobertura_psf analfabetismo  gini   idh
  <dbl> <dbl>      <dbl>         <dbl>         <dbl>         <dbl> <dbl> <dbl>
1     1  9.99       74.4          25.1          73.4           7.8 0.569 0.95
2     2 23.7        62.4          19.4          73.3          19.4 0.588 0.938
3     3  1.5        82.4          36.2          72.8           2.7 0.521 0.95
4     4  2.47       75.4          28.6          68.8           8.9 0.492 0.95
5     5 16.1        68.3          21.2          78.1          13.5 0.45  0.95
6     6  1.5        87.2          30.4          94.7           5   0.506 0.95
# i 3 more variables: renda_percapita <dbl>, leitos_mil <dbl>, regiao <fct>
```

Número de observações

```r
nrow(dados)
```

```
[1] 300
```

Estrutura da base de dados

```r
glimpse(dados)
```

```
Rows: 300
Columns: 11
$ id              <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16,~
$ tmi             <dbl> 9.99, 23.74, 1.50, 2.47, 16.11, 1.50, 35.44, 30.30, 10~
```

```
$ saneamento      <dbl> 74.4, 62.4, 82.4, 75.4, 68.3, 87.2, 48.0, 52.3, 72.7, ~
$ pib_percapita   <dbl> 25.09, 19.41, 36.21, 28.64, 21.22, 30.43, 11.36, 13.41~
$ cobertura_psf   <dbl> 73.4, 73.3, 72.8, 68.8, 78.1, 94.7, 58.8, 59.0, 66.3, ~
$ analfabetismo   <dbl> 7.8, 19.4, 2.7, 8.9, 13.5, 5.0, 22.2, 24.1, 7.7, 8.8, ~
$ gini            <dbl> 0.569, 0.588, 0.521, 0.492, 0.450, 0.506, 0.552, 0.596~
$ idh             <dbl> 0.950, 0.938, 0.950, 0.950, 0.950, 0.950, 0.802, 0.842~
$ renda_percapita <dbl> 1693, 1445, 2443, 2094, 1451, 2084, 753, 927, 1657, 20~
$ leitos_mil      <dbl> 0.84, 2.21, 2.76, 2.02, 1.60, 2.72, 0.89, 0.20, 0.20, ~
$ regiao          <fct> Sul, Nordeste, Sudeste, Sudeste, Nordeste, Sudeste, No~
```

Estatísticas descritivas detalhadas

```r
skim(dados)
```

Tabela 1: Data summary

Name	dados
Number of rows	300
Number of columns	11
Column type frequency:	
factor	1
numeric	10
Group variables	None

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
regiao	0	1	FALSE	5	Sud: 99, Nor: 81, Sul: 50, Nor: 38

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
id	0	1.00	150.50	86.75	1.00	75.75	150.50	225.25	300.00	

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
tmi	0	1.00	19.89	12.32	1.50	9.86	18.57	28.89	48.82	
saneamento	5	0.98	63.26	16.22	14.60	52.15	63.80	74.40	99.50	
pib_percapita	0	1.00	20.11	11.59	3.00	11.67	19.64	27.22	53.87	
cobertura_psf	4	0.99	64.44	12.72	32.70	56.08	64.95	73.40	98.80	
analfabetismo	3	0.99	11.95	6.23	0.00	6.80	11.40	16.10	30.40	
gini	0	1.00	0.55	0.07	0.36	0.50	0.56	0.60	0.73	
idh	0	1.00	0.87	0.11	0.60	0.79	0.95	0.95	0.95	
renda_percapita	0	1.00	1419.57	808.69	150.00	797.25	1411.00	1947.25	3710.00	
leitos_mil	3	0.99	1.03	0.70	0.20	0.40	0.94	1.46	3.30	

Variáveis da base de dados

Variável	Significado	Unidade
tmi	Taxa de mortalidade infantil	óbitos por 1000 nascidos vivos
saneamento	Percentual da população com acesso a saneamento básico	%
pib_percapita	Produto Interno Bruto per capita	R$
psf	Cobertura da Estratégia Saúde da Família	%
analfabetismo	Taxa de analfabetismo	%
gini	Índice de desigualdade de renda	0 a 1
idh	Índice de Desenvolvimento Humano	0 a 1
renda_percapita	Renda média per capita	R$
leitos	Número de leitos hospitalares	leitos por 1000 habitantes
regiao	Região geográfica do Brasil (Norte, Nordeste, Centro-Oeste, Sudeste, Sul)	categórica

Análise Exploratória de Dados

Antes da construção de modelos estatísticos, é importante realizar uma análise exploratória da base de dados. Essa etapa permite compreender melhor as características das variáveis, identificar possíveis valores ausentes e detectar a presença de valores extremos (outliers).

Verificação de valores ausentes

```r
colSums(is.na(dados))
```

```
             id             tmi      saneamento   pib_percapita   cobertura_psf
              0               0               5               0               4
  analfabetismo            gini             idh renda_percapita      leitos_mil
              3               0               0               0               3
         regiao
              0
```

Distribuição da Taxa de Mortalidade Infantil

```r
ggplot(dados, aes(x = tmi)) +
  geom_histogram(bins = 10, fill = "lightblue", color = "black") +
  labs(
    title = "Distribuição da Taxa de Mortalidade Infantil",
    x = "TMI",
    y = "Frequência"
  )
```

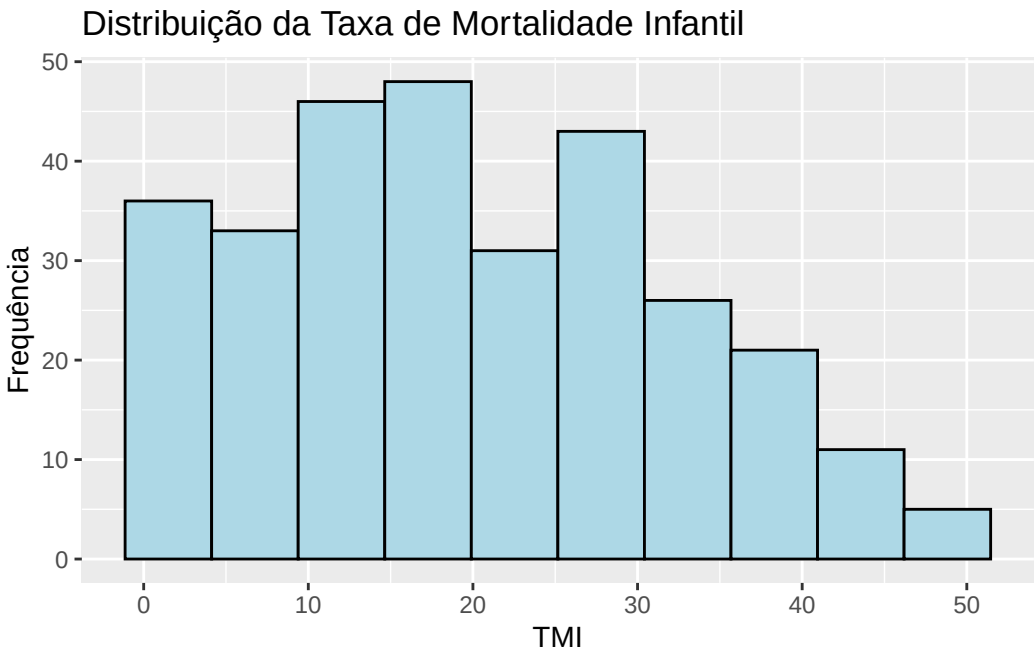

Identificação de possíveis outliers

```
boxplot(
  dados$tmi,
  main = "Boxplot da Taxa de Mortalidade Infantil",
  ylab = "TMI"
)
```

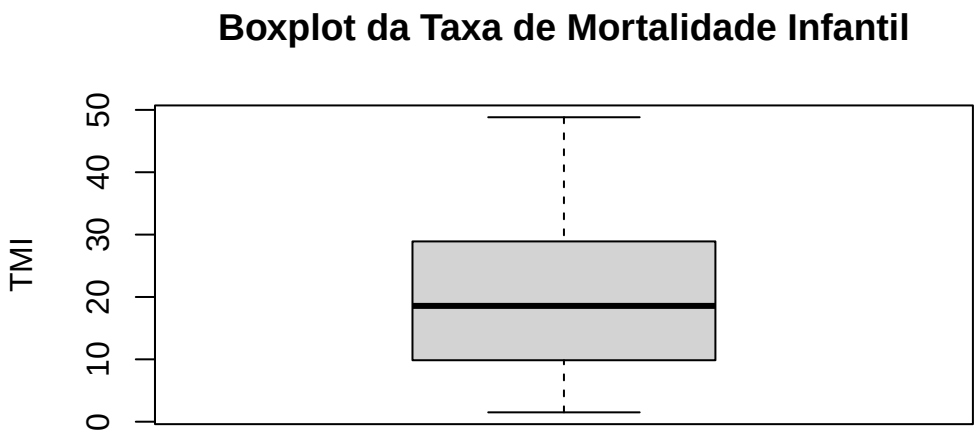

A análise exploratória permite identificar padrões iniciais nos dados e possíveis inconsistências na base de dados, como valores ausentes ou observações extremas.

Análises Bivariadas

Somente entre variáveis numéricas

```
dados_num <- dados %>% select_if(is.numeric)

corr_matrix <- cor(dados_num, use = "complete.obs")

corr_matrix
```

```
                         id         tmi  saneamento pib_percapita cobertura_psf
id               1.00000000  0.05572141 -0.06349452   -0.04288378   -0.07267058
tmi              0.05572141  1.00000000 -0.85115146   -0.89982770   -0.55900389
saneamento      -0.06349452 -0.85115146  1.00000000    0.71049678    0.39192419
pib_percapita   -0.04288378 -0.89982770  0.71049678    1.00000000    0.57965857
cobertura_psf   -0.07267058 -0.55900389  0.39192419    0.57965857    1.00000000
analfabetismo   -0.03356514  0.76416643 -0.69466637   -0.56610033   -0.19850305
```

```
gini             0.07057474  0.62638193 -0.49069753   -0.64278201   -0.44274169
idh             -0.07200699 -0.83249153  0.61109906    0.82482297    0.51343627
renda_percapita -0.03850265 -0.88859628  0.69886259    0.98962862    0.60476741
leitos_mil      -0.09451450 -0.07013885  0.04628789    0.10633944    0.09951698
                analfabetismo         gini         idh renda_percapita
id                -0.03356514  0.070574744 -0.07200699     -0.03850265
tmi                0.76416643  0.626381929 -0.83249153     -0.88859628
saneamento        -0.69466637 -0.490697527  0.61109906      0.69886259
pib_percapita     -0.56610033 -0.642782006  0.82482297      0.98962862
cobertura_psf     -0.19850305 -0.442741695  0.51343627      0.60476741
analfabetismo      1.00000000  0.316760029 -0.63223917     -0.52344981
gini               0.31676003  1.000000000 -0.55575414     -0.67599082
idh               -0.63223917 -0.555754135  1.00000000      0.82560233
renda_percapita   -0.52344981 -0.675990819  0.82560233      1.00000000
leitos_mil        -0.02574811  0.003553445  0.03713843      0.08589125
                  leitos_mil
id              -0.094514505
tmi             -0.070138851
saneamento       0.046287886
pib_percapita    0.106339436
cobertura_psf    0.099516978
analfabetismo   -0.025748107
gini             0.003553445
idh              0.037138427
renda_percapita  0.085891254
leitos_mil       1.000000000
```

```r
corrplot(
  corr_matrix,
  method = "color",
  type = "upper",
  addCoef.col = "black",
  number.cex = 0.65,
  tl.cex = 0.75,
  tl.srt = 45
)
```

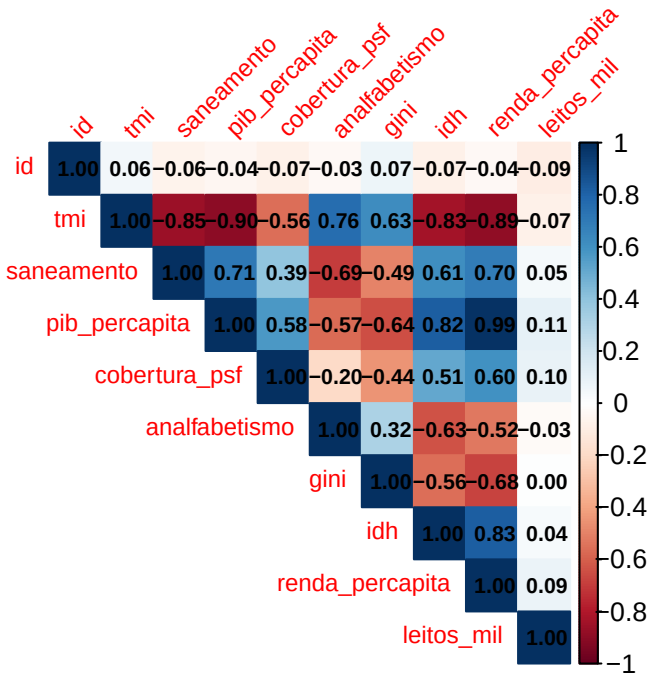

A análise da matriz de correlação indica relações importantes entre as variáveis socioeconômicas e a taxa de mortalidade infantil (TMI).

Observa-se uma forte correlação negativa entre TMI e renda per capita (-0.89), indicando que regiões ou municípios com maior renda tendem a apresentar menores níveis de mortalidade infantil. De forma semelhante, o Índice de Desenvolvimento Humano (IDH) também apresenta correlação negativa elevada com a TMI (-0.83), sugerindo que melhores condições de desenvolvimento humano estão associadas a menores taxas de mortalidade infantil.

O acesso ao saneamento também apresenta correlação negativa significativa com a mortalidade infantil (-0.85), reforçando a importância da infraestrutura sanitária para a saúde pública.

Por outro lado, o analfabetismo apresenta correlação positiva com a TMI (0.76), indicando que locais com maiores níveis de analfabetismo tendem a registrar maiores taxas de mortalidade infantil.

Esses resultados sugerem que fatores socioeconômicos, educacionais e de infraestrutura estão fortemente associados às condições de saúde infantil.

Variável numérica em função de categórica

```
ggplot(dados, aes(x = regiao, y = tmi)) +
  geom_boxplot(fill = "lightblue") +
```

```r
  theme_minimal() +
  labs(
    title = "Taxa de Mortalidade Infantil por Região do Brasil",
    x = "Região",
    y = "TMI"
  )
```

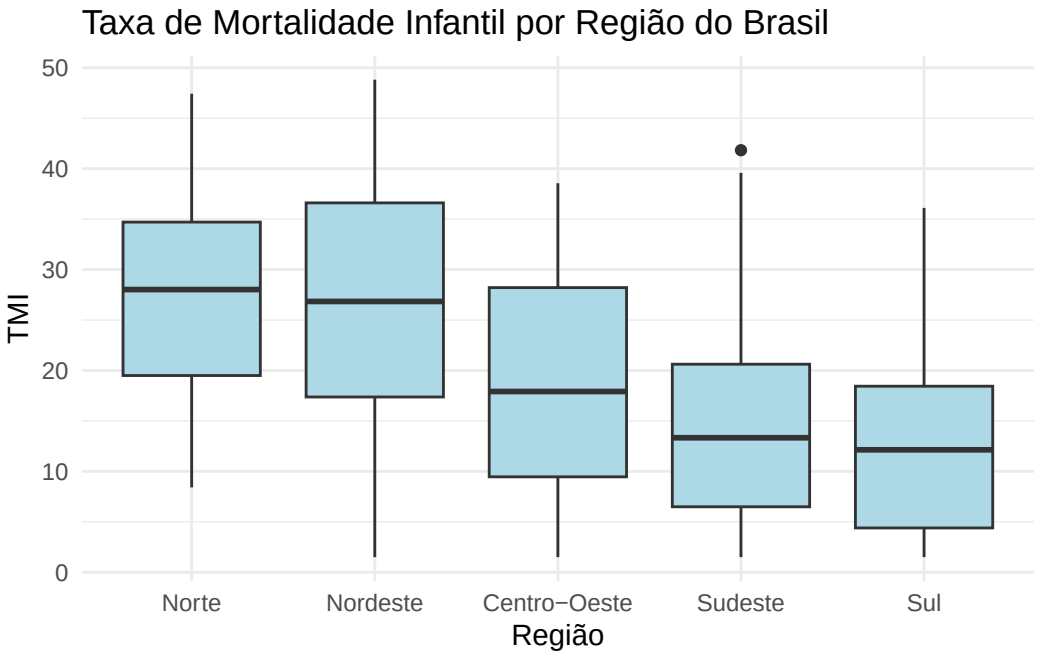

Observa-se que a taxa de mortalidade infantil apresenta diferenças importantes entre as cinco regiões do Brasil (Norte, Nordeste, Centro-Oeste, Sudeste e Sul).

As regiões Norte e Nordeste apresentam medianas mais elevadas de TMI, além de maior dispersão dos valores, indicando maior variabilidade entre os municípios dessas regiões.

Em contraste, as regiões Sul e Sudeste apresentam medianas significativamente menores, sugerindo melhores condições socioeconômicas e de acesso a serviços de saúde.

A região Centro-Oeste apresenta valores intermediários, situando-se entre os grupos de maior e menor mortalidade infantil.

Esses resultados indicam desigualdades regionais importantes nas condições de saúde e desenvolvimento.

Relação entre renda e mortalidade infantil

```
ggplot(dados, aes(x = renda_percapita, y = tmi)) +
  geom_point() +
  geom_smooth(method = "lm") +
  theme_minimal() +
  labs(
    title = "Renda per capita vs Mortalidade Infantil",
    x = "Renda per capita",
    y = "TMI"
  )
```

```
`geom_smooth()` using formula = 'y ~ x'
```

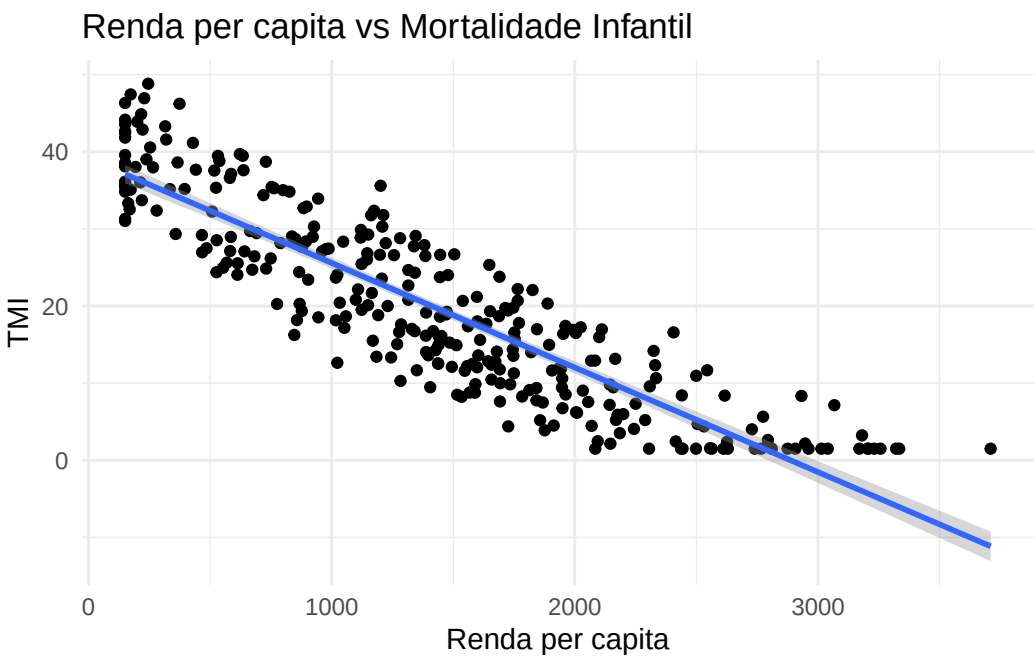

A relação entre renda per capita e mortalidade infantil apresenta um padrão claramente negativo.

Observa-se que à medida que a renda per capita aumenta, a taxa de mortalidade infantil tende a diminuir. A linha de regressão ajustada confirma essa tendência, indicando uma associação linear negativa entre as variáveis.

Esse resultado sugere que municípios com maior renda possuem melhores condições de vida, maior acesso a serviços de saúde, nutrição adequada e infraestrutura básica, fatores que contribuem para a redução da mortalidade infantil.

Relação entre saneamento e mortalidade infantil

```r
ggplot(dados, aes(x = saneamento, y = tmi)) +
  geom_point() +
  geom_smooth(method = "lm") +
  theme_minimal() +
  labs(
    title = "Saneamento vs Mortalidade Infantil",
    x = "Acesso ao saneamento (%)",
    y = "TMI"
  )
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 5 rows containing non-finite outside the scale range
(`stat_smooth()`).
```

```
Warning: Removed 5 rows containing missing values or values outside the scale range
(`geom_point()`).
```

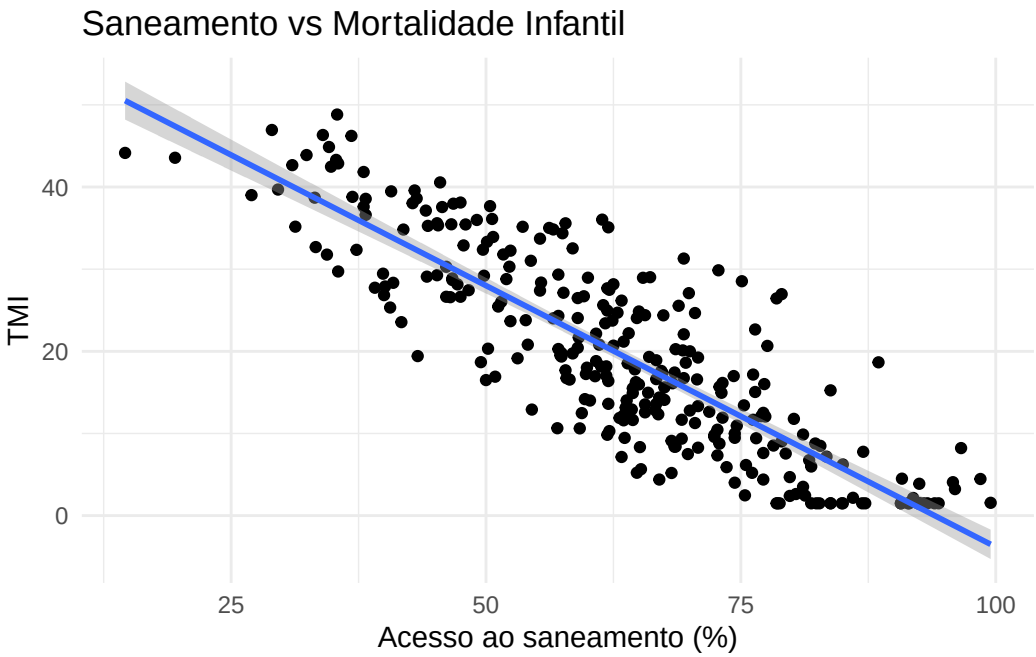

A análise do gráfico indica uma relação negativa entre acesso ao saneamento e mortalidade infantil.

Observa-se que municípios com maior porcentagem de acesso ao saneamento tendem a apresentar menores taxas de mortalidade infantil. A linha de regressão reforça essa tendência, indicando uma associação inversa entre as variáveis.

Esse resultado evidencia a importância do saneamento básico para a saúde pública, uma vez que melhores condições sanitárias reduzem a exposição a doenças infecciosas e melhoram as condições de vida da população.

Ajuste do Modelo Inicial de Regressão

Inicialmente foi ajustado um modelo de regressão linear múltipla considerando todas as variáveis explicativas disponíveis na base de dados.

```
modelo_inicial <- lm(tmi ~ saneamento + pib_percapita + cobertura_psf + analfabetismo
                     + gini + idh + renda_percapita + leitos_mil + regiao, data = dados)

summary(modelo_inicial)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + renda_percapita + leitos_mil +
    regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-6.9691 -1.9633 -0.1574  1.7480  8.6566

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.330419   3.902576  12.384  < 2e-16 ***
saneamento          -0.171109   0.019995  -8.558 8.58e-16 ***
pib_percapita       -0.138327   0.124559  -1.111 0.267753
cobertura_psf       -0.092532   0.016702  -5.540 7.13e-08 ***
analfabetismo        0.388790   0.061298   6.343 9.38e-10 ***
gini                11.673323   3.294386   3.543 0.000465 ***
idh                -15.201162   3.207358  -4.739 3.46e-06 ***
renda_percapita     -0.003950   0.001859  -2.124 0.034542 *
leitos_mil           0.030203   0.239846   0.126 0.899883
regiaoNordeste       0.138602   0.559327   0.248 0.804476
regiaoCentro-Oeste  -1.871339   0.945829  -1.979 0.048879 *
regiaoSudeste       -2.214032   0.822309  -2.692 0.007533 **
regiaoSul           -2.350338   0.869009  -2.705 0.007270 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.712 on 272 degrees of freedom
  (15 observations deleted due to missingness)
Multiple R-squared:  0.9515,    Adjusted R-squared:  0.9493
F-statistic: 444.3 on 12 and 272 DF,  p-value: < 2.2e-16
```

Observa-se que o coeficiente de determinação ajustado (R^2 ajustado) obtido foi de 0.9493, indicando que aproximadamente 94,93% da variabilidade da TMI é explicada pelas variáveis independentes incluídas no modelo, o que sugere um bom nível de ajuste aos dados.

Temos também que a variável leitos_mil, que indica o número de leitos hospitalares por mil habitantes, apresenta valor-p elevado, indicando menor evidência de associação com a variável resposta do modelo.

Diagnóstico de Multicolinearidade

```r
vif(modelo_inicial)
```

```
                     GVIF Df GVIF^(1/(2*Df))
saneamento       3.950051  1        1.987474
pib_percapita   78.995250  1        8.887927
cobertura_psf    1.725906  1        1.313737
analfabetismo    5.415994  1        2.327229
gini             2.001197  1        1.414637
idh              4.759025  1        2.181519
renda_percapita 85.884282  1        9.267377
leitos_mil       1.070969  1        1.034876
regiao           6.190327  4        1.255926
```

A análise de multicolinearidade do modelo inicial, através do VIF, indicou uma alta correlação entre pib_percapita e renda_percapita.

Esse resultado é esperado, visto que, além do que foi exposto pela matriz de correlação da análise bivariada dos dados, ambas representam indicadores de nível econômico da população,. Dessa forma, na etapa de seleção do melhor modelo, será considerada a remoção de uma dessas variáveis a fim de reduzir o problema de multicolinearidade.

Seleção de Modelo

Com ou Sem Leitos por Mil Habitantes

```r
modelo_sem_leitos <- update(modelo_inicial, . ~ . - leitos_mil)

summary(modelo_sem_leitos)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + renda_percapita + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
```

```
-6.9439 -1.9591 -0.1769  1.7438  8.6669

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.546180   3.867076  12.554  < 2e-16 ***
saneamento          -0.168661   0.019699  -8.562 7.90e-16 ***
pib_percapita       -0.137200   0.122287  -1.122 0.262859
cobertura_psf       -0.091893   0.016483  -5.575 5.89e-08 ***
analfabetismo        0.389987   0.060928   6.401 6.61e-10 ***
gini                11.239609   3.235335   3.474 0.000595 ***
idh                -15.272965   3.179523  -4.804 2.56e-06 ***
renda_percapita     -0.004027   0.001834  -2.196 0.028944 *
regiaoNordeste       0.164035   0.554554   0.296 0.767608
regiaoCentro-Oeste  -1.834676   0.939356  -1.953 0.051816 .
regiaoSudeste       -2.223071   0.817353  -2.720 0.006946 **
regiaoSul           -2.359487   0.861637  -2.738 0.006576 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.698 on 276 degrees of freedom
  (12 observations deleted due to missingness)
Multiple R-squared:  0.9522,    Adjusted R-squared:  0.9503
F-statistic: 499.5 on 11 and 276 DF,  p-value: < 2.2e-16
```

```r
AIC(modelo_inicial)
```

```
[1] 1392.245
```

```r
AIC(modelo_sem_leitos)
```

```
[1] 1402.693
```

Foi avaliada a remoção da variável leitos_mil, uma vez que essa variável apresentou p-valor elevado no modelo inicial. Para isso, foi ajustado um modelo alternativo excluindo essa variável.

Observou-se que o R^2 ajustado apresentou pequeno aumento, passando de aproximadamente 0.9493 para 0.9503, indicando leve melhora na proporção de variabilidade explicada pelo modelo.

Entretanto, ao comparar os modelos utilizando o Critério de Informação de Akaike (AIC), verificou-se que o modelo inicial apresentou AIC = 1392,245, enquanto o modelo sem a variável leitos_mil apresentou AIC = 1402,693.

Como a diferença nos valores de AIC foi maior que 10, conclui-se que a remoção da variável leitos por mil habitantes resultou em pior desempenho do modelo. Dessa forma, optou-se por manter essa variável no modelo.

PIB per capita ou Renda per capita

Apenas PIB per capita

```r
modelo_apenas_pib <- update(modelo_inicial, . ~ . - renda_percapita)

summary(modelo_apenas_pib)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + leitos_mil + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-7.4769 -1.8333 -0.1165  1.6979  8.6422

Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.14659    3.92664  12.262  < 2e-16 ***
saneamento          -0.18006    0.01967  -9.153  < 2e-16 ***
pib_percapita       -0.39409    0.03214 -12.262  < 2e-16 ***
cobertura_psf       -0.09786    0.01662  -5.889 1.14e-08 ***
analfabetismo        0.38379    0.06165   6.226 1.80e-09 ***
gini                13.50565    3.19986   4.221 3.32e-05 ***
idh                -15.94191    3.20880  -4.968 1.19e-06 ***
leitos_mil           0.08416    0.24003   0.351   0.7261
regiaoNordeste       0.10281    0.56266   0.183   0.8551
regiaoCentro-Oeste  -1.74789    0.95010  -1.840   0.0669 .
regiaoSudeste       -1.68911    0.78934  -2.140   0.0332 *
regiaoSul           -1.86679    0.84405  -2.212   0.0278 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.73 on 273 degrees of freedom
  (15 observations deleted due to missingness)
```

```
Multiple R-squared:  0.9507,    Adjusted R-squared:  0.9487
F-statistic: 478.2 on 11 and 273 DF,  p-value: < 2.2e-16
```

Apenas Renda per capita

```r
modelo_apenas_renda <- update(modelo_inicial, . ~ . - pib_percapita)

summary(modelo_apenas_renda)
```

```
Call:
lm(formula = tmi ~ saneamento + cobertura_psf + analfabetismo +
    gini + idh + renda_percapita + leitos_mil + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-6.6989 -1.9321 -0.1331  1.7600  8.5183

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         4.865e+01  3.894e+00  12.494  < 2e-16 ***
saneamento         -1.689e-01  1.990e-02  -8.485 1.39e-15 ***
cobertura_psf      -9.087e-02  1.664e-02  -5.460 1.07e-07 ***
analfabetismo       3.921e-01  6.125e-02   6.402 6.67e-10 ***
gini                1.101e+01  3.240e+00   3.396 0.000785 ***
idh                -1.523e+01  3.209e+00  -4.746 3.34e-06 ***
renda_percapita    -5.946e-03  4.769e-04 -12.468  < 2e-16 ***
leitos_mil         -5.685e-03  2.378e-01  -0.024 0.980941
regiaoNordeste      1.504e-01  5.595e-01   0.269 0.788204
regiaoCentro-Oeste -1.886e+00  9.461e-01  -1.993 0.047263 *
regiaoSudeste      -2.469e+00  7.900e-01  -3.125 0.001969 **
regiaoSul          -2.581e+00  8.443e-01  -3.057 0.002461 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.714 on 273 degrees of freedom
  (15 observations deleted due to missingness)
Multiple R-squared:  0.9512,    Adjusted R-squared:  0.9493
F-statistic: 484.2 on 11 and 273 DF,  p-value: < 2.2e-16
```

Comparação de valores AIC

```r
AIC(modelo_apenas_pib)
```

```
[1] 1394.935
```

```r
AIC(modelo_apenas_renda)
```

```
[1] 1391.534
```

Considerando a forte multicolinearidade observada entre as variáveis PIB per capita e Renda per capita, foram ajustados dois modelos alternativos: um mantendo apenas a variável PIB per capita e outro mantendo apenas a variável renda per capita.

Observou-se que o modelo contendo apenas PIB per capita apresentou R^2 ajustado = 0,9487 e AIC = 1394,935, enquanto o modelo contendo apenas renda per capita apresentou R^2 ajustado = 0,9493 e AIC = 1391,534.

Como o modelo com renda per capita apresentou maior poder explicativo e menor valor de AIC, conclui-se que ele apresenta melhor desempenho. Dessa forma, optou-se por manter a variável renda per capita e remover a variável PIB per capita, resultando em um modelo mais parcimonioso e estatisticamente adequado.

```r
modelo_final <- update(modelo_inicial, . ~ . - pib_percapita)

vif(modelo_final)
```

```
                    GVIF Df GVIF^(1/(2*Df))
saneamento      3.909669  1        1.977288
cobertura_psf   1.712071  1        1.308461
analfabetismo   5.403114  1        2.324460
gini            1.934448  1        1.390844
idh             4.758719  1        2.181449
renda_percapita 5.645016  1        2.375924
leitos_mil      1.051526  1        1.025439
regiao          4.973436  4        1.222031
```

Observou-se que as variáveis de renda e analfabetismo apresentaram valores VIF maiores que 5, porém inferiores a 10, indicando multicolinearidade moderada.

Tal resultado é esperado, uma vez que ambas as variáveis representam indicadores socioeconômicos relacionados ao nível de desenvolvimento, sendo plausível a existência de correlação entre elas. Como os valores de VIF permanecem abaixo do limite crítico frequentemente utilizado (VIF > 10), conclui-se que não há evidência de multicolinearidade severa capaz de comprometer a estabilidade das estimativas do modelo.

Dessa forma, optou-se por manter ambas as variáveis no modelo, considerando sua relevância interpretativa para explicar a variabilidade da taxa de mortalidade infantil.

Checando pressupostos do MRLM

Plot do R base

```
plot(modelo_final)
```

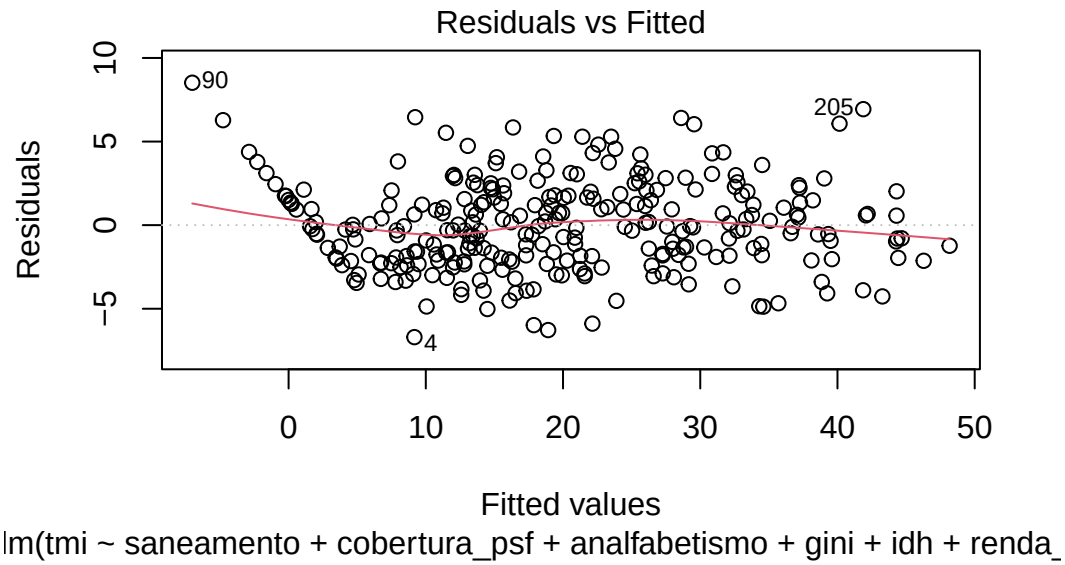

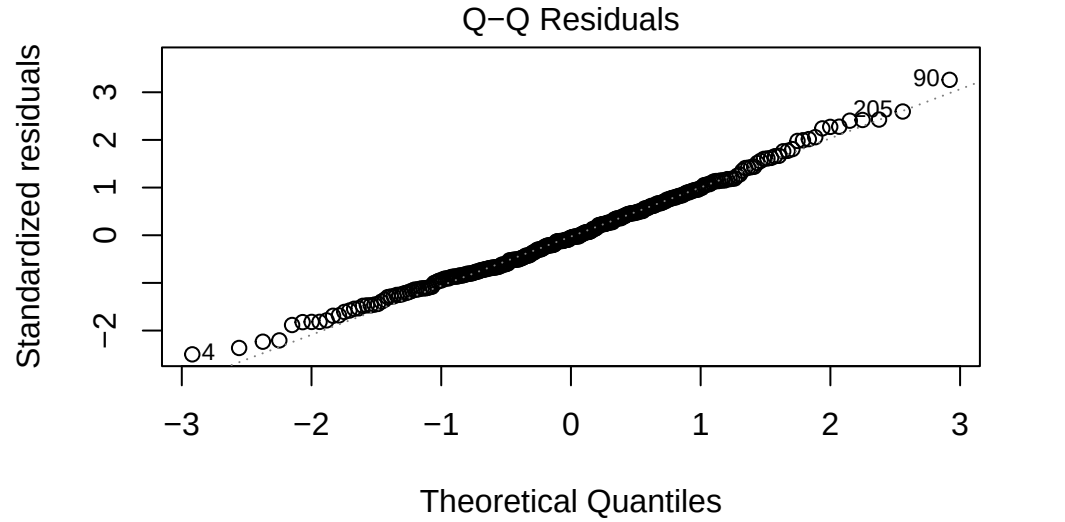
Q−Q Residuals
Standardized residuals
Theoretical Quantiles
lm(tmi ~ saneamento + cobertura_psf + analfabetismo + gini + idh + renda_
90
205
4

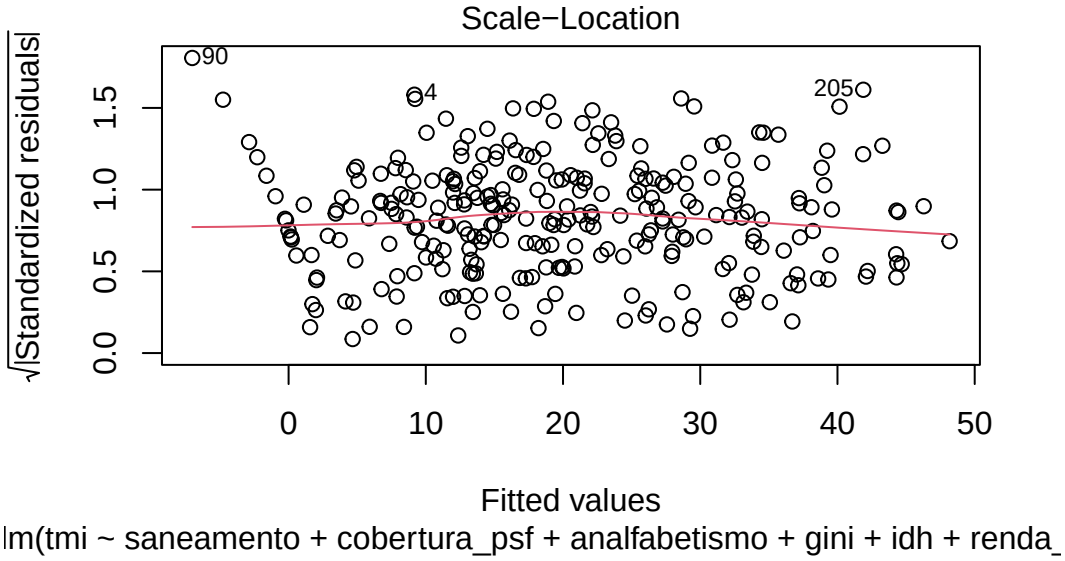
Scale−Location
√|Standardized residuals|
Fitted values
lm(tmi ~ saneamento + cobertura_psf + analfabetismo + gini + idh + renda_
90
4
205

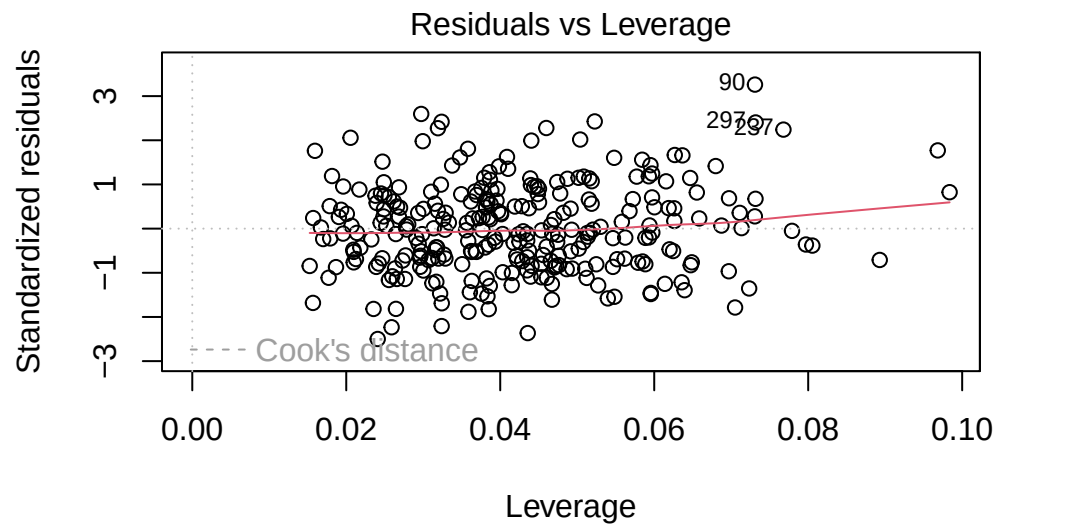

Checagem manual do Easystats

```
check_normality(modelo_final)
```

```
OK: residuals appear as normally distributed (p = 0.219).
```

```
check_heteroscedasticity(modelo_final)
```

```
OK: Error variance appears to be homoscedastic (p = 0.609).
```

```
check_outliers(modelo_final)
```

```
OK: No outliers detected.
- Based on the following method and threshold: cook (0.92).
- For variable: (Whole model)
```

```
check_collinearity(modelo_final)
```

```
# Check for Multicollinearity

Low Correlation

          Term  VIF   VIF 95% CI adj. VIF Tolerance Tolerance 95% CI
    saneamento 3.91 [3.25, 4.77]     1.98      0.26     [0.21, 0.31]
 cobertura_psf 1.71 [1.49, 2.04]     1.31      0.58     [0.49, 0.67]
          gini 1.93 [1.67, 2.31]     1.39      0.52     [0.43, 0.60]
           idh 4.76 [3.93, 5.83]     2.18      0.21     [0.17, 0.25]
    leitos_mil 1.05 [1.00, 1.55]     1.03      0.95     [0.65, 1.00]
        regiao 4.97 [4.10, 6.09]     1.22      0.20     [0.16, 0.24]

Moderate Correlation

            Term  VIF   VIF 95% CI adj. VIF Tolerance Tolerance 95% CI
   analfabetismo 5.40 [4.44, 6.63]     2.32      0.19     [0.15, 0.22]
 renda_percapita 5.65 [4.64, 6.93]     2.38      0.18     [0.14, 0.22]
```

```r
check_autocorrelation(modelo_final)
```

```
OK: Residuals appear to be independent and not autocorrelated (p = 0.852).
```

Análise gráfica de todos os pressupostos

```r
check_model(modelo_final)
```

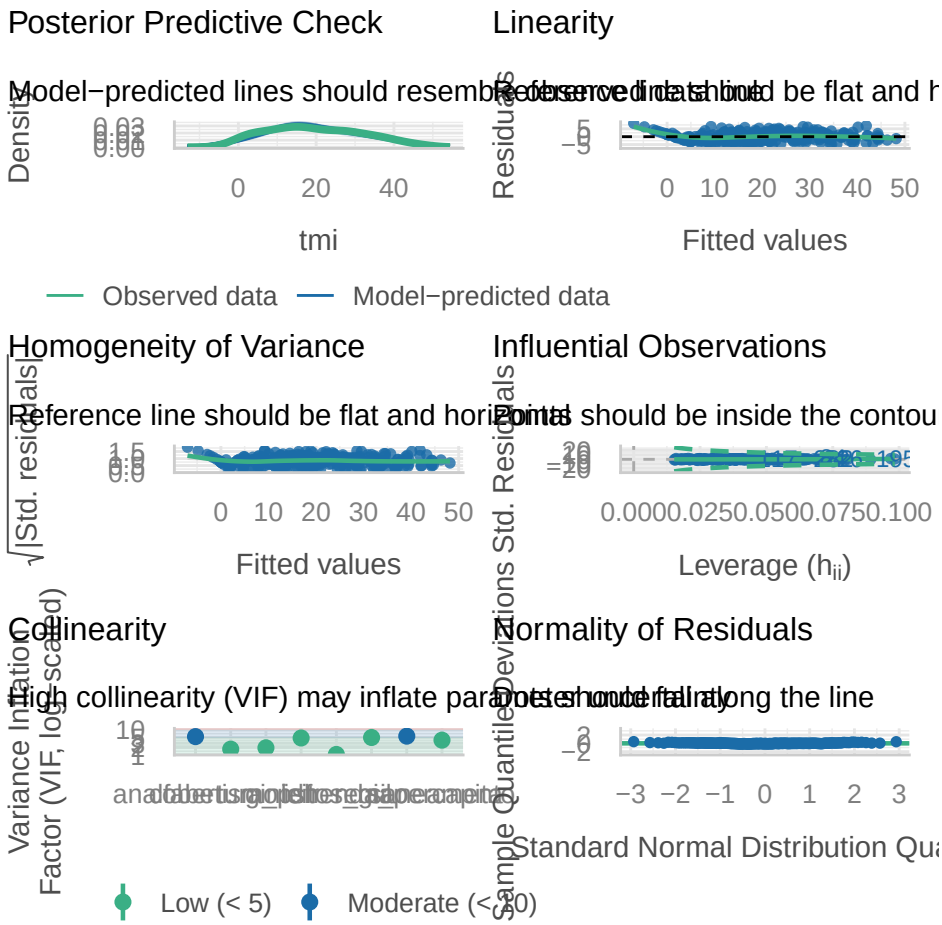
Posterior Predictive Check
Model−predicted lines should resemble observed data
Density
tmi
Linearity
Reference line should be flat and h
Residuals
Fitted values
Homogeneity of Variance
Reference line should be flat and horizontal
√|Std. residuals|
Fitted values
Influential Observations
Points should be inside the contou
Std. Residuals
Leverage (hii)
Collinearity
High collinearity (VIF) may inflate parameter uncertainty
Variance Inflation Factor (VIF, log-scaled)
Low (< 5)
Moderate (<10)
Normality of Residuals
Points should fall along the line
Sample Quantiles Deviations
Standard Normal Distribution Qua