Análise da Taxa de Mortalidade Infantil e Indicadores Socioeconômicos

Adriano Porto Kauan Brito

2026-03-15

Introdução

A taxa de mortalidade infantil (TMI) é um dos principais indicadores utilizados para avaliar as condições de saúde e desenvolvimento socioeconômico de uma população. Esse indicador reflete não apenas a qualidade da assistência médica disponível, mas também aspectos estruturais da sociedade, como condições de saneamento, renda, educação e desigualdade social.

Diversos fatores socioeconômicos podem influenciar diretamente os níveis de mortalidade infantil. Entre esses fatores destacam-se o acesso ao saneamento básico, o nível de renda da população, a cobertura de serviços de atenção primária à saúde, o nível educacional da população e indicadores de desigualdade econômica.

Neste estudo busca-se analisar a relação entre a taxa de mortalidade infantil e diferentes indicadores socioeconômicos e de infraestrutura de saúde. Para isso, será utilizada uma base de dados contendo variáveis relacionadas a condições econômicas, sociais e de acesso à saúde.

O objetivo principal desta análise é investigar possíveis associações entre a taxa de mortalidade infantil e variáveis socioeconômicas, além de realizar uma análise exploratória inicial da base de dados.

Descrição da Base de Dados

A base de dados utilizada neste estudo contém informações relacionadas a indicadores socioeconômicos e de saúde pública. Cada observação corresponde a uma unidade geográfica, podendo representar estados ou municípios, contendo variáveis explicativas que podem influenciar a taxa de mortalidade infantil.

Leitura da base de dados

```r
dados <- read_excel("dados.xlsx")

dados$regiao <- factor(
  dados$regiao,
  levels = c("Norte", "Nordeste", "Centro-Oeste", "Sudeste", "Sul")
)

head(dados)
```

```
# A tibble: 6 x 11
     id   tmi saneamento pib_percapita cobertura_psf analfabetismo  gini   idh
  <dbl> <dbl>      <dbl>         <dbl>         <dbl>         <dbl> <dbl> <dbl>
1     1  9.99       74.4          25.1          73.4           7.8 0.569 0.95
2     2 23.7        62.4          19.4          73.3          19.4 0.588 0.938
3     3  1.5        82.4          36.2          72.8           2.7 0.521 0.95
4     4  2.47       75.4          28.6          68.8           8.9 0.492 0.95
5     5 16.1        68.3          21.2          78.1          13.5 0.45  0.95
6     6  1.5        87.2          30.4          94.7           5   0.506 0.95
# i 3 more variables: renda_percapita <dbl>, leitos_mil <dbl>, regiao <fct>
```

Número de observações

```r
nrow(dados)
```

```
[1] 300
```

Estrutura da base de dados

```r
glimpse(dados)
```

```
Rows: 300
Columns: 11
$ id              <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16,~
$ tmi             <dbl> 9.99, 23.74, 1.50, 2.47, 16.11, 1.50, 35.44, 30.30, 10~
```

```
$ saneamento      <dbl> 74.4, 62.4, 82.4, 75.4, 68.3, 87.2, 48.0, 52.3, 72.7, ~
$ pib_percapita   <dbl> 25.09, 19.41, 36.21, 28.64, 21.22, 30.43, 11.36, 13.41~
$ cobertura_psf   <dbl> 73.4, 73.3, 72.8, 68.8, 78.1, 94.7, 58.8, 59.0, 66.3, ~
$ analfabetismo   <dbl> 7.8, 19.4, 2.7, 8.9, 13.5, 5.0, 22.2, 24.1, 7.7, 8.8, ~
$ gini            <dbl> 0.569, 0.588, 0.521, 0.492, 0.450, 0.506, 0.552, 0.596~
$ idh             <dbl> 0.950, 0.938, 0.950, 0.950, 0.950, 0.950, 0.802, 0.842~
$ renda_percapita <dbl> 1693, 1445, 2443, 2094, 1451, 2084, 753, 927, 1657, 20~
$ leitos_mil      <dbl> 0.84, 2.21, 2.76, 2.02, 1.60, 2.72, 0.89, 0.20, 0.20, ~
$ regiao          <fct> Sul, Nordeste, Sudeste, Sudeste, Nordeste, Sudeste, No~
```

Estatísticas descritivas detalhadas

```r
skim(dados)
```

Tabela 1: Data summary

Name	dados
Number of rows	300
Number of columns	11
Column type frequency:	
factor	1
numeric	10
Group variables	None

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
regiao	0	1	FALSE	5	Sud: 99, Nor: 81, Sul: 50, Nor: 38

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
id	0	1.00	150.50	86.75	1.00	75.75	150.50	225.25	300.00	

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
tmi	0	1.00	19.89	12.32	1.50	9.86	18.57	28.89	48.82	
saneamento	5	0.98	63.26	16.22	14.60	52.15	63.80	74.40	99.50	
pib_percapita	0	1.00	20.11	11.59	3.00	11.67	19.64	27.22	53.87	
cobertura_psf	4	0.99	64.44	12.72	32.70	56.08	64.95	73.40	98.80	
analfabetismo	3	0.99	11.95	6.23	0.00	6.80	11.40	16.10	30.40	
gini	0	1.00	0.55	0.07	0.36	0.50	0.56	0.60	0.73	
idh	0	1.00	0.87	0.11	0.60	0.79	0.95	0.95	0.95	
renda_percapita	0	1.00	1419.57	808.69	150.00	797.25	1411.00	1947.25	3710.00	
leitos_mil	3	0.99	1.03	0.70	0.20	0.40	0.94	1.46	3.30	

Variáveis da base de dados

Variável	Significado	Unidade
tmi	Taxa de mortalidade infantil	óbitos por 1000 nascidos vivos
saneamento	Percentual da população com acesso a saneamento básico	%
pib_percapita	Produto Interno Bruto per capita	R$
psf	Cobertura da Estratégia Saúde da Família	%
analfabetismo	Taxa de analfabetismo	%
gini	Índice de desigualdade de renda	0 a 1
idh	Índice de Desenvolvimento Humano	0 a 1
renda_percapita	Renda média per capita	R$
leitos	Número de leitos hospitalares	leitos por 1000 habitantes
regiao	Região geográfica do Brasil (Norte, Nordeste, Centro-Oeste, Sudeste, Sul)	categórica

Análise Exploratória de Dados

Antes da construção de modelos estatísticos, é importante realizar uma análise exploratória da base de dados. Essa etapa permite compreender melhor as características das variáveis, identificar possíveis valores ausentes e detectar a presença de valores extremos (outliers).

Verificação de valores ausentes

```r
colSums(is.na(dados))
```

```
             id             tmi      saneamento   pib_percapita   cobertura_psf
              0               0               5               0               4
  analfabetismo            gini             idh renda_percapita      leitos_mil
              3               0               0               0               3
         regiao
              0
```

Distribuição da Taxa de Mortalidade Infantil

```r
ggplot(dados, aes(x = tmi)) +
  geom_histogram(bins = 10, fill = "lightblue", color = "black") +
  labs(
    title = "Distribuição da Taxa de Mortalidade Infantil",
    x = "TMI",
    y = "Frequência"
  )
```

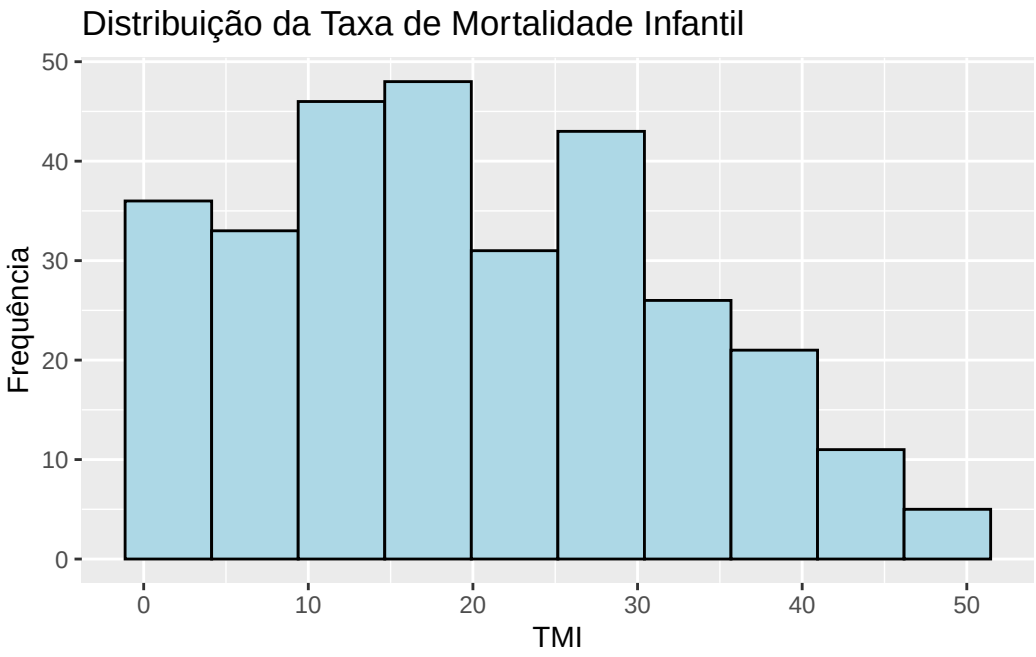

Identificação de possíveis outliers

```
boxplot(
  dados$tmi,
  main = "Boxplot da Taxa de Mortalidade Infantil",
  ylab = "TMI"
)
```

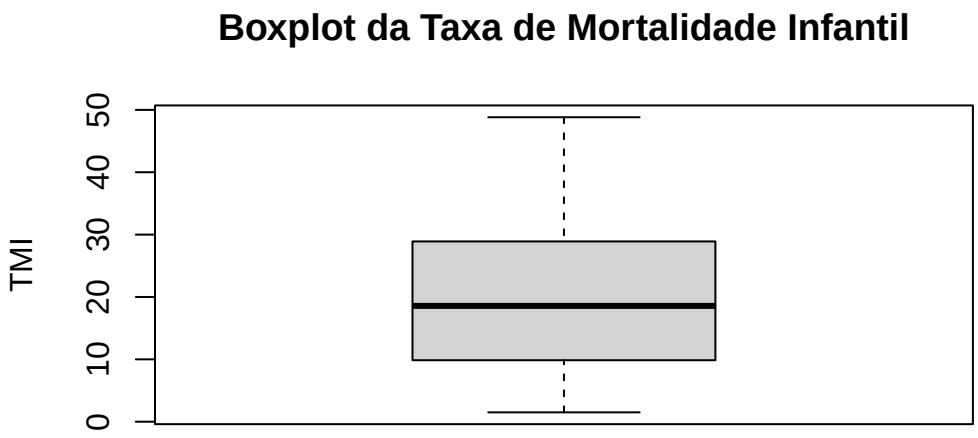

A análise exploratória permite identificar padrões iniciais nos dados e possíveis inconsistências na base de dados, como valores ausentes ou observações extremas.

Análises Bivariadas

Somente entre variáveis numéricas

```
dados_num <- dados %>% select_if(is.numeric)

corr_matrix <- cor(dados_num, use = "complete.obs")

corr_matrix
```

```
                         id         tmi  saneamento pib_percapita cobertura_psf
id               1.00000000  0.05572141 -0.06349452   -0.04288378   -0.07267058
tmi              0.05572141  1.00000000 -0.85115146   -0.89982770   -0.55900389
saneamento      -0.06349452 -0.85115146  1.00000000    0.71049678    0.39192419
pib_percapita   -0.04288378 -0.89982770  0.71049678    1.00000000    0.57965857
cobertura_psf   -0.07267058 -0.55900389  0.39192419    0.57965857    1.00000000
analfabetismo   -0.03356514  0.76416643 -0.69466637   -0.56610033   -0.19850305
```

```
gini             0.07057474  0.62638193 -0.49069753   -0.64278201   -0.44274169
idh             -0.07200699 -0.83249153  0.61109906    0.82482297    0.51343627
renda_percapita -0.03850265 -0.88859628  0.69886259    0.98962862    0.60476741
leitos_mil      -0.09451450 -0.07013885  0.04628789    0.10633944    0.09951698
                analfabetismo         gini         idh renda_percapita
id                -0.03356514  0.070574744 -0.07200699     -0.03850265
tmi                0.76416643  0.626381929 -0.83249153     -0.88859628
saneamento        -0.69466637 -0.490697527  0.61109906      0.69886259
pib_percapita     -0.56610033 -0.642782006  0.82482297      0.98962862
cobertura_psf     -0.19850305 -0.442741695  0.51343627      0.60476741
analfabetismo      1.00000000  0.316760029 -0.63223917     -0.52344981
gini               0.31676003  1.000000000 -0.55575414     -0.67599082
idh               -0.63223917 -0.555754135  1.00000000      0.82560233
renda_percapita   -0.52344981 -0.675990819  0.82560233      1.00000000
leitos_mil        -0.02574811  0.003553445  0.03713843      0.08589125
                  leitos_mil
id              -0.094514505
tmi             -0.070138851
saneamento       0.046287886
pib_percapita    0.106339436
cobertura_psf    0.099516978
analfabetismo   -0.025748107
gini             0.003553445
idh              0.037138427
renda_percapita  0.085891254
leitos_mil       1.000000000
```

```r
corrplot(
  corr_matrix,
  method = "color",
  type = "upper",
  addCoef.col = "black",
  number.cex = 0.65,
  tl.cex = 0.75,
  tl.srt = 45
)
```

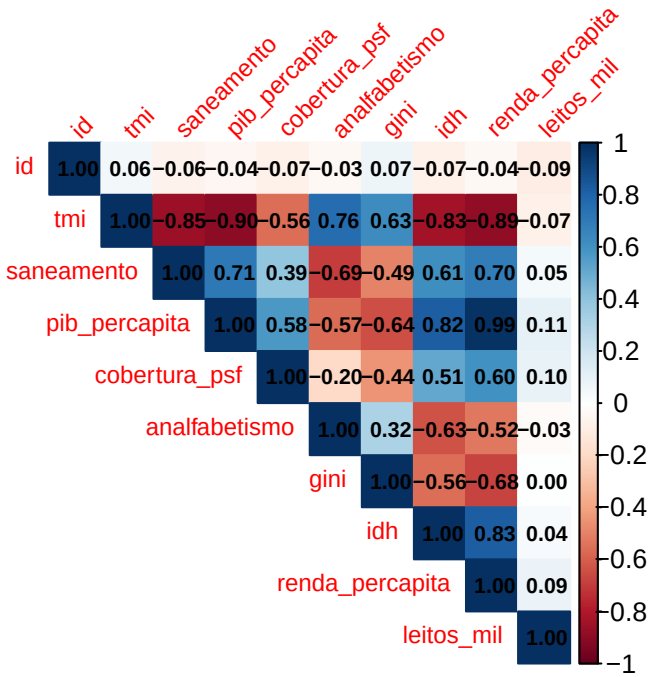

A análise da matriz de correlação indica relações importantes entre as variáveis socioeconômicas e a taxa de mortalidade infantil (TMI).

Observa-se uma forte correlação negativa entre TMI e renda per capita (-0.89), indicando que regiões ou municípios com maior renda tendem a apresentar menores níveis de mortalidade infantil. De forma semelhante, o Índice de Desenvolvimento Humano (IDH) também apresenta correlação negativa elevada com a TMI (-0.83), sugerindo que melhores condições de desenvolvimento humano estão associadas a menores taxas de mortalidade infantil.

O acesso ao saneamento também apresenta correlação negativa significativa com a mortalidade infantil (-0.85), reforçando a importância da infraestrutura sanitária para a saúde pública.

Por outro lado, o analfabetismo apresenta correlação positiva com a TMI (0.76), indicando que locais com maiores níveis de analfabetismo tendem a registrar maiores taxas de mortalidade infantil.

Esses resultados sugerem que fatores socioeconômicos, educacionais e de infraestrutura estão fortemente associados às condições de saúde infantil.

Variável numérica em função de categórica

```
ggplot(dados, aes(x = regiao, y = tmi)) +
  geom_boxplot(fill = "lightblue") +
```

```r
  theme_minimal() +
  labs(
    title = "Taxa de Mortalidade Infantil por Região do Brasil",
    x = "Região",
    y = "TMI"
  )
```

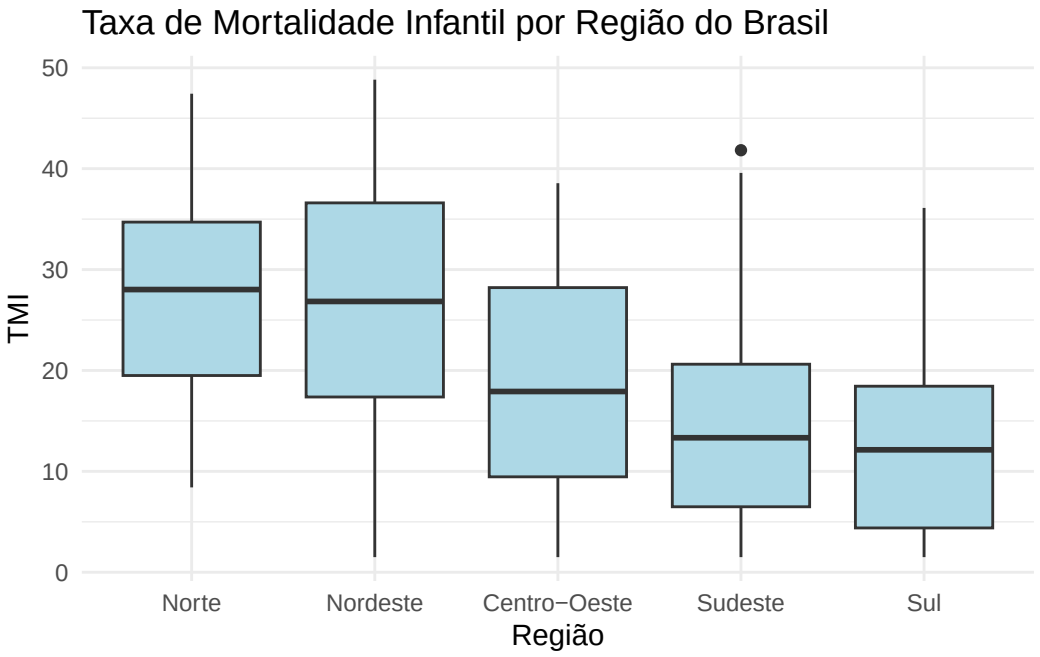

Observa-se que a taxa de mortalidade infantil apresenta diferenças importantes entre as cinco regiões do Brasil (Norte, Nordeste, Centro-Oeste, Sudeste e Sul).

As regiões Norte e Nordeste apresentam medianas mais elevadas de TMI, além de maior dispersão dos valores, indicando maior variabilidade entre os municípios dessas regiões.

Em contraste, as regiões Sul e Sudeste apresentam medianas significativamente menores, sugerindo melhores condições socioeconômicas e de acesso a serviços de saúde.

A região Centro-Oeste apresenta valores intermediários, situando-se entre os grupos de maior e menor mortalidade infantil.

Esses resultados indicam desigualdades regionais importantes nas condições de saúde e desenvolvimento.

Relação entre renda e mortalidade infantil

```
ggplot(dados, aes(x = renda_percapita, y = tmi)) +
  geom_point() +
  geom_smooth(method = "lm") +
  theme_minimal() +
  labs(
    title = "Renda per capita vs Mortalidade Infantil",
    x = "Renda per capita",
    y = "TMI"
  )
```

```
`geom_smooth()` using formula = 'y ~ x'
```

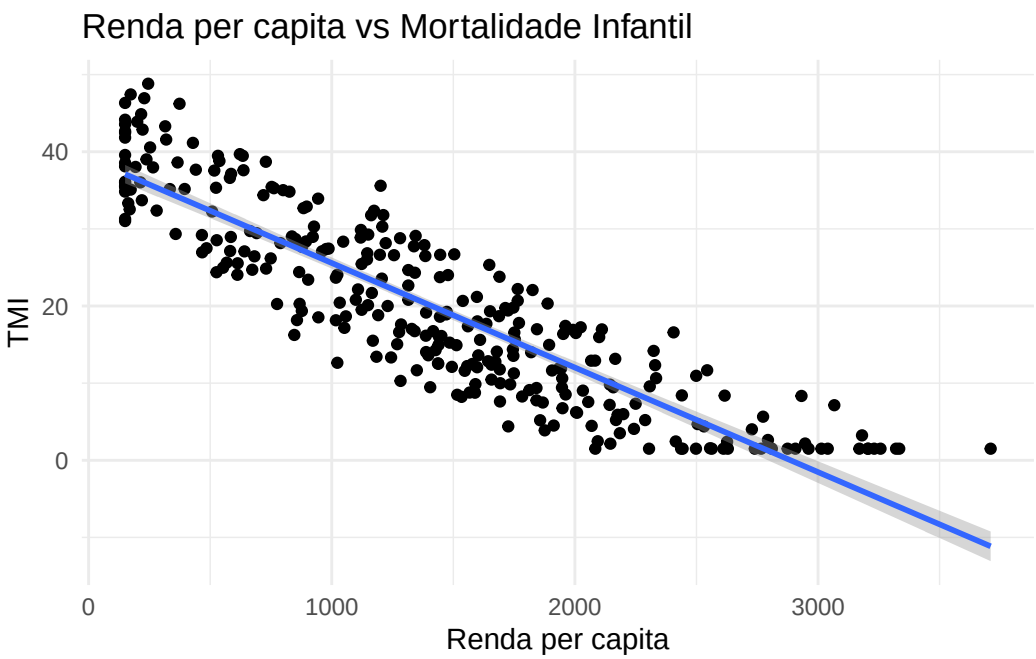

A relação entre renda per capita e mortalidade infantil apresenta um padrão claramente negativo.

Observa-se que à medida que a renda per capita aumenta, a taxa de mortalidade infantil tende a diminuir. A linha de regressão ajustada confirma essa tendência, indicando uma associação linear negativa entre as variáveis.

Esse resultado sugere que municípios com maior renda possuem melhores condições de vida, maior acesso a serviços de saúde, nutrição adequada e infraestrutura básica, fatores que contribuem para a redução da mortalidade infantil.

Relação entre saneamento e mortalidade infantil

```r
ggplot(dados, aes(x = saneamento, y = tmi)) +
  geom_point() +
  geom_smooth(method = "lm") +
  theme_minimal() +
  labs(
    title = "Saneamento vs Mortalidade Infantil",
    x = "Acesso ao saneamento (%)",
    y = "TMI"
  )
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 5 rows containing non-finite outside the scale range
(`stat_smooth()`).
```

```
Warning: Removed 5 rows containing missing values or values outside the scale range
(`geom_point()`).
```

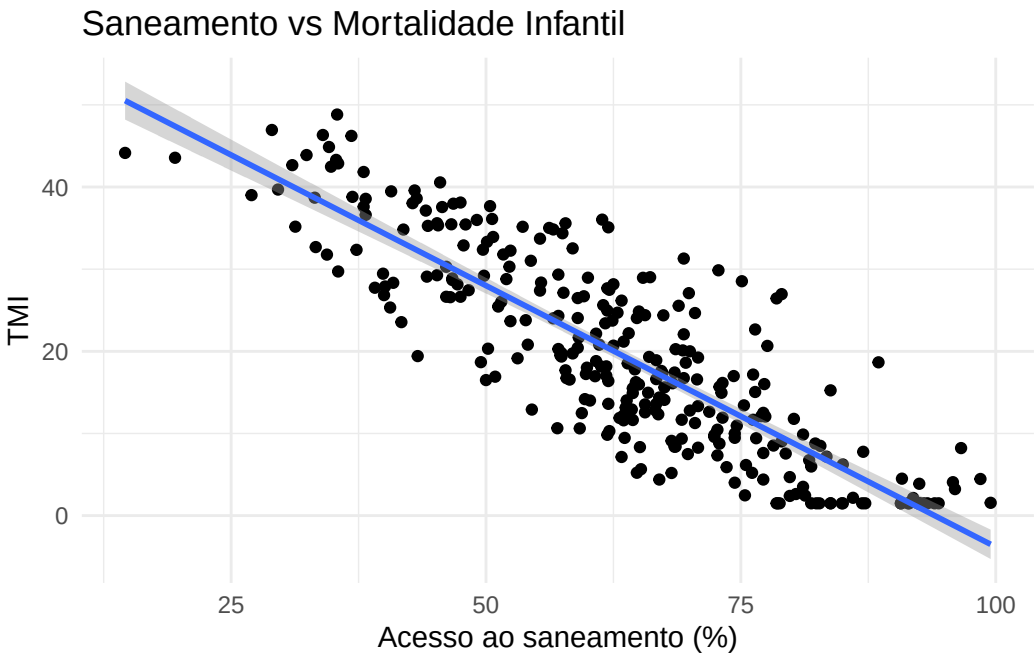

A análise do gráfico indica uma relação negativa entre acesso ao saneamento e mortalidade infantil.

Observa-se que municípios com maior porcentagem de acesso ao saneamento tendem a apresentar menores taxas de mortalidade infantil. A linha de regressão reforça essa tendência, indicando uma associação inversa entre as variáveis.

Esse resultado evidencia a importância do saneamento básico para a saúde pública, uma vez que melhores condições sanitárias reduzem a exposição a doenças infecciosas e melhoram as condições de vida da população.

Ajuste do Modelo Inicial de Regressão

Inicialmente foi ajustado um modelo de regressão linear múltipla considerando todas as variáveis explicativas disponíveis na base de dados.

```
modelo_inicial <- lm(tmi ~ saneamento + pib_percapita + cobertura_psf + analfabetismo
                     + gini + idh + renda_percapita + leitos_mil + regiao, data = dados)

summary(modelo_inicial)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + renda_percapita + leitos_mil +
    regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-6.9691 -1.9633 -0.1574  1.7480  8.6566

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.330419   3.902576  12.384  < 2e-16 ***
saneamento          -0.171109   0.019995  -8.558 8.58e-16 ***
pib_percapita       -0.138327   0.124559  -1.111 0.267753
cobertura_psf       -0.092532   0.016702  -5.540 7.13e-08 ***
analfabetismo        0.388790   0.061298   6.343 9.38e-10 ***
gini                11.673323   3.294386   3.543 0.000465 ***
idh                -15.201162   3.207358  -4.739 3.46e-06 ***
renda_percapita     -0.003950   0.001859  -2.124 0.034542 *
leitos_mil           0.030203   0.239846   0.126 0.899883
regiaoNordeste       0.138602   0.559327   0.248 0.804476
regiaoCentro-Oeste  -1.871339   0.945829  -1.979 0.048879 *
regiaoSudeste       -2.214032   0.822309  -2.692 0.007533 **
regiaoSul           -2.350338   0.869009  -2.705 0.007270 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.712 on 272 degrees of freedom
  (15 observations deleted due to missingness)
Multiple R-squared:  0.9515,    Adjusted R-squared:  0.9493
F-statistic: 444.3 on 12 and 272 DF,  p-value: < 2.2e-16
```

Observa-se que o coeficiente de determinação ajustado (R^2 ajustado) obtido foi de 0.9493, indicando que aproximadamente 94,93% da variabilidade da TMI é explicada pelas variáveis independentes incluídas no modelo, o que sugere um bom nível de ajuste aos dados.

Temos também que a variável leitos_mil, que indica o número de leitos hospitalares por mil habitantes, apresenta valor-p elevado, indicando menor evidência de associação com a variável resposta do modelo.

Diagnóstico de Multicolinearidade

```r
vif(modelo_inicial)
```

```
                     GVIF Df GVIF^(1/(2*Df))
saneamento       3.950051  1        1.987474
pib_percapita   78.995250  1        8.887927
cobertura_psf    1.725906  1        1.313737
analfabetismo    5.415994  1        2.327229
gini             2.001197  1        1.414637
idh              4.759025  1        2.181519
renda_percapita 85.884282  1        9.267377
leitos_mil       1.070969  1        1.034876
regiao           6.190327  4        1.255926
```

A análise de multicolinearidade do modelo inicial, através do VIF, indicou uma alta correlação entre pib_percapita e renda_percapita.

Esse resultado é esperado, visto que, além do que foi exposto pela matriz de correlação da análise bivariada dos dados, ambas representam indicadores de nível econômico da população,. Dessa forma, na etapa de seleção do melhor modelo, será considerada a remoção de uma dessas variáveis a fim de reduzir o problema de multicolinearidade.

Seleção de Modelo

Com ou Sem Leitos por Mil Habitantes

```r
modelo_sem_leitos <- update(modelo_inicial, . ~ . - leitos_mil)

summary(modelo_sem_leitos)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + renda_percapita + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
```

```
-6.9439 -1.9591 -0.1769  1.7438  8.6669

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.546180   3.867076  12.554  < 2e-16 ***
saneamento          -0.168661   0.019699  -8.562 7.90e-16 ***
pib_percapita       -0.137200   0.122287  -1.122 0.262859
cobertura_psf       -0.091893   0.016483  -5.575 5.89e-08 ***
analfabetismo        0.389987   0.060928   6.401 6.61e-10 ***
gini                11.239609   3.235335   3.474 0.000595 ***
idh                -15.272965   3.179523  -4.804 2.56e-06 ***
renda_percapita     -0.004027   0.001834  -2.196 0.028944 *
regiaoNordeste       0.164035   0.554554   0.296 0.767608
regiaoCentro-Oeste  -1.834676   0.939356  -1.953 0.051816 .
regiaoSudeste       -2.223071   0.817353  -2.720 0.006946 **
regiaoSul           -2.359487   0.861637  -2.738 0.006576 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.698 on 276 degrees of freedom
  (12 observations deleted due to missingness)
Multiple R-squared:  0.9522,    Adjusted R-squared:  0.9503
F-statistic: 499.5 on 11 and 276 DF,  p-value: < 2.2e-16
```

```r
AIC(modelo_inicial)
```

```
[1] 1392.245
```

```r
AIC(modelo_sem_leitos)
```

```
[1] 1402.693
```

Foi avaliada a remoção da variável leitos_mil, uma vez que essa variável apresentou p-valor elevado no modelo inicial. Para isso, foi ajustado um modelo alternativo excluindo essa variável.

Observou-se que o R^2 ajustado apresentou pequeno aumento, passando de aproximadamente 0.9493 para 0.9503, indicando leve melhora na proporção de variabilidade explicada pelo modelo.

Entretanto, ao comparar os modelos utilizando o Critério de Informação de Akaike (AIC), verificou-se que o modelo inicial apresentou AIC = 1392,245, enquanto o modelo sem a variável leitos_mil apresentou AIC = 1402,693.

Como a diferença nos valores de AIC foi maior que 10, conclui-se que a remoção da variável leitos por mil habitantes resultou em pior desempenho do modelo. Dessa forma, optou-se por manter essa variável no modelo.

PIB per capita ou Renda per capita

Apenas PIB per capita

```r
modelo_apenas_pib <- update(modelo_inicial, . ~ . - renda_percapita)

summary(modelo_apenas_pib)
```

```
Call:
lm(formula = tmi ~ saneamento + pib_percapita + cobertura_psf +
    analfabetismo + gini + idh + leitos_mil + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-7.4769 -1.8333 -0.1165  1.6979  8.6422

Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
(Intercept)         48.14659    3.92664  12.262  < 2e-16 ***
saneamento          -0.18006    0.01967  -9.153  < 2e-16 ***
pib_percapita       -0.39409    0.03214 -12.262  < 2e-16 ***
cobertura_psf       -0.09786    0.01662  -5.889 1.14e-08 ***
analfabetismo        0.38379    0.06165   6.226 1.80e-09 ***
gini                13.50565    3.19986   4.221 3.32e-05 ***
idh                -15.94191    3.20880  -4.968 1.19e-06 ***
leitos_mil           0.08416    0.24003   0.351   0.7261
regiaoNordeste       0.10281    0.56266   0.183   0.8551
regiaoCentro-Oeste  -1.74789    0.95010  -1.840   0.0669 .
regiaoSudeste       -1.68911    0.78934  -2.140   0.0332 *
regiaoSul           -1.86679    0.84405  -2.212   0.0278 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.73 on 273 degrees of freedom
  (15 observations deleted due to missingness)
```

```
Multiple R-squared:  0.9507,    Adjusted R-squared:  0.9487
F-statistic: 478.2 on 11 and 273 DF,  p-value: < 2.2e-16
```

Apenas Renda per capita

```r
modelo_apenas_renda <- update(modelo_inicial, . ~ . - pib_percapita)

summary(modelo_apenas_renda)
```

```
Call:
lm(formula = tmi ~ saneamento + cobertura_psf + analfabetismo +
    gini + idh + renda_percapita + leitos_mil + regiao, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-6.6989 -1.9321 -0.1331  1.7600  8.5183

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         4.865e+01  3.894e+00  12.494  < 2e-16 ***
saneamento         -1.689e-01  1.990e-02  -8.485 1.39e-15 ***
cobertura_psf      -9.087e-02  1.664e-02  -5.460 1.07e-07 ***
analfabetismo       3.921e-01  6.125e-02   6.402 6.67e-10 ***
gini                1.101e+01  3.240e+00   3.396 0.000785 ***
idh                -1.523e+01  3.209e+00  -4.746 3.34e-06 ***
renda_percapita    -5.946e-03  4.769e-04 -12.468  < 2e-16 ***
leitos_mil         -5.685e-03  2.378e-01  -0.024 0.980941
regiaoNordeste      1.504e-01  5.595e-01   0.269 0.788204
regiaoCentro-Oeste -1.886e+00  9.461e-01  -1.993 0.047263 *
regiaoSudeste      -2.469e+00  7.900e-01  -3.125 0.001969 **
regiaoSul          -2.581e+00  8.443e-01  -3.057 0.002461 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.714 on 273 degrees of freedom
  (15 observations deleted due to missingness)
Multiple R-squared:  0.9512,    Adjusted R-squared:  0.9493
F-statistic: 484.2 on 11 and 273 DF,  p-value: < 2.2e-16
```

Comparação de valores AIC

```r
AIC(modelo_apenas_pib)
```

```
[1] 1394.935
```

```r
AIC(modelo_apenas_renda)
```

```
[1] 1391.534
```

Considerando a forte multicolinearidade observada entre as variáveis PIB per capita e Renda per capita, foram ajustados dois modelos alternativos: um mantendo apenas a variável PIB per capita e outro mantendo apenas a variável renda per capita.

Observou-se que o modelo contendo apenas PIB per capita apresentou R^2 ajustado = 0,9487 e AIC = 1394,935, enquanto o modelo contendo apenas renda per capita apresentou R^2 ajustado = 0,9493 e AIC = 1391,534.

Como o modelo com renda per capita apresentou maior poder explicativo e menor valor de AIC, conclui-se que ele apresenta melhor desempenho. Dessa forma, optou-se por manter a variável renda per capita e remover a variável PIB per capita, resultando em um modelo mais parcimonioso e estatisticamente adequado.

```r
modelo_final <- update(modelo_inicial, . ~ . - pib_percapita)

vif(modelo_final)
```

```
                    GVIF Df GVIF^(1/(2*Df))
saneamento      3.909669  1        1.977288
cobertura_psf   1.712071  1        1.308461
analfabetismo   5.403114  1        2.324460
gini            1.934448  1        1.390844
idh             4.758719  1        2.181449
renda_percapita 5.645016  1        2.375924
leitos_mil      1.051526  1        1.025439
regiao          4.973436  4        1.222031
```

Observou-se que as variáveis de renda e analfabetismo apresentaram valores VIF maiores que 5, porém inferiores a 10, indicando multicolinearidade moderada.

Tal resultado é esperado, uma vez que ambas as variáveis representam indicadores socioeconômicos relacionados ao nível de desenvolvimento, sendo plausível a existência de correlação entre elas. Como os valores de VIF permanecem abaixo do limite crítico frequentemente utilizado (VIF > 10), conclui-se que não há evidência de multicolinearidade severa capaz de comprometer a estabilidade das estimativas do modelo.

Dessa forma, optou-se por manter ambas as variáveis no modelo, considerando sua relevância interpretativa para explicar a variabilidade da taxa de mortalidade infantil.

Checando pressupostos do MRLM

Plot do R base

```
plot(modelo_final)
```

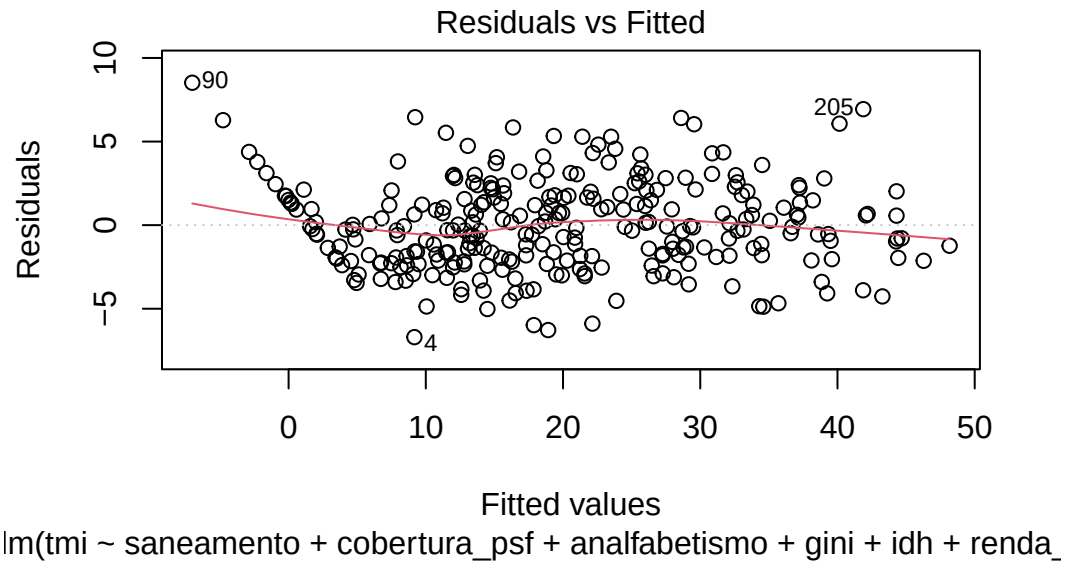

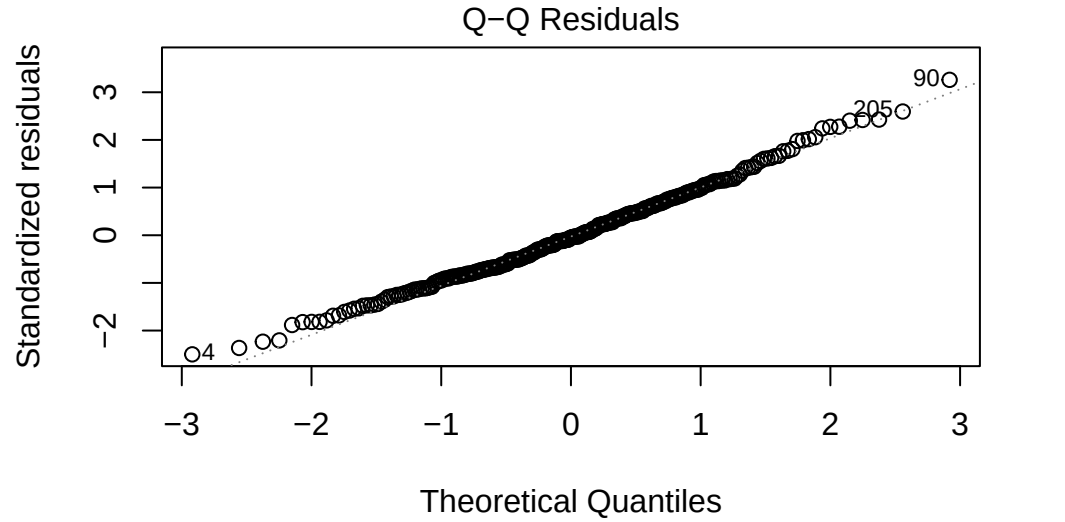
Q−Q Residuals
Standardized residuals
Theoretical Quantiles
lm(tmi ~ saneamento + cobertura_psf + analfabetismo + gini + idh + renda_
90
205
4

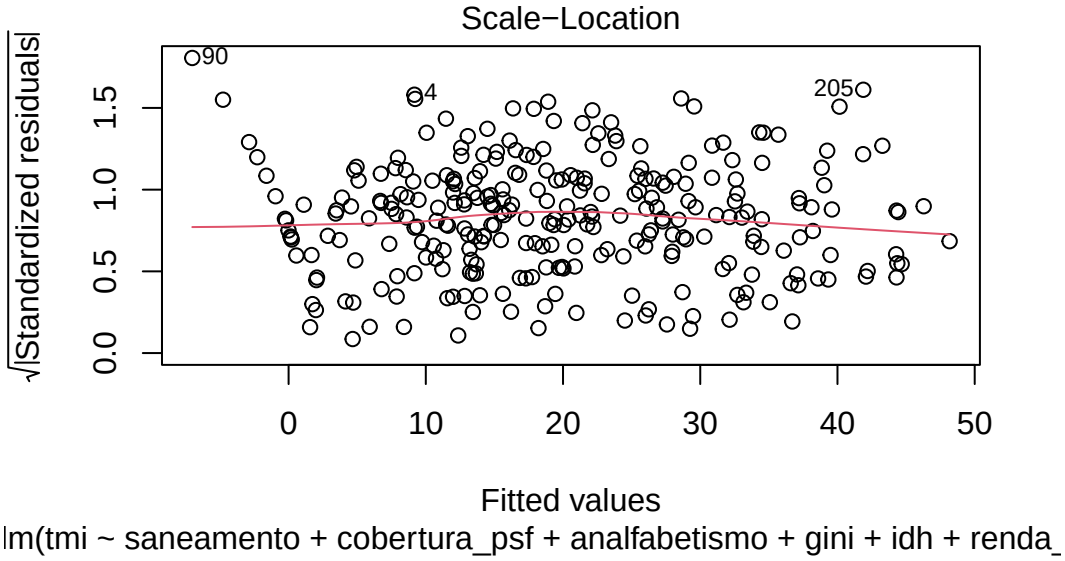
Scale−Location
√|Standardized residuals|
Fitted values
lm(tmi ~ saneamento + cobertura_psf + analfabetismo + gini + idh + renda_
90
4
205

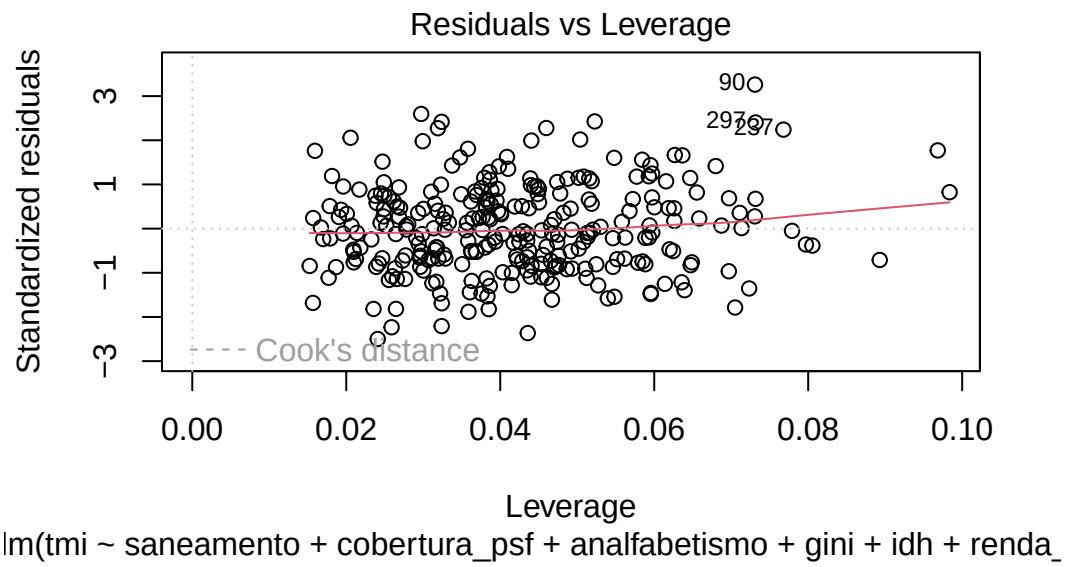

Checagem manual do Easystats

```
check_normality(modelo_final)
```

```
OK: residuals appear as normally distributed (p = 0.219).
```

```
check_heteroscedasticity(modelo_final)
```

```
OK: Error variance appears to be homoscedastic (p = 0.609).
```

```
check_outliers(modelo_final)
```

```
OK: No outliers detected.
- Based on the following method and threshold: cook (0.92).
- For variable: (Whole model)
```

```
check_collinearity(modelo_final)
```

```
# Check for Multicollinearity

Low Correlation

          Term  VIF   VIF 95% CI adj. VIF Tolerance Tolerance 95% CI
    saneamento 3.91 [3.25, 4.77]     1.98      0.26     [0.21, 0.31]
 cobertura_psf 1.71 [1.49, 2.04]     1.31      0.58     [0.49, 0.67]
          gini 1.93 [1.67, 2.31]     1.39      0.52     [0.43, 0.60]
           idh 4.76 [3.93, 5.83]     2.18      0.21     [0.17, 0.25]
    leitos_mil 1.05 [1.00, 1.55]     1.03      0.95     [0.65, 1.00]
        regiao 4.97 [4.10, 6.09]     1.22      0.20     [0.16, 0.24]

Moderate Correlation

            Term  VIF   VIF 95% CI adj. VIF Tolerance Tolerance 95% CI
   analfabetismo 5.40 [4.44, 6.63]     2.32      0.19     [0.15, 0.22]
 renda_percapita 5.65 [4.64, 6.93]     2.38      0.18     [0.14, 0.22]
```

```r
check_autocorrelation(modelo_final)
```

```
OK: Residuals appear to be independent and not autocorrelated (p = 0.850).
```

Análise gráfica de todos os pressupostos

```r
check_model(modelo_final)
```

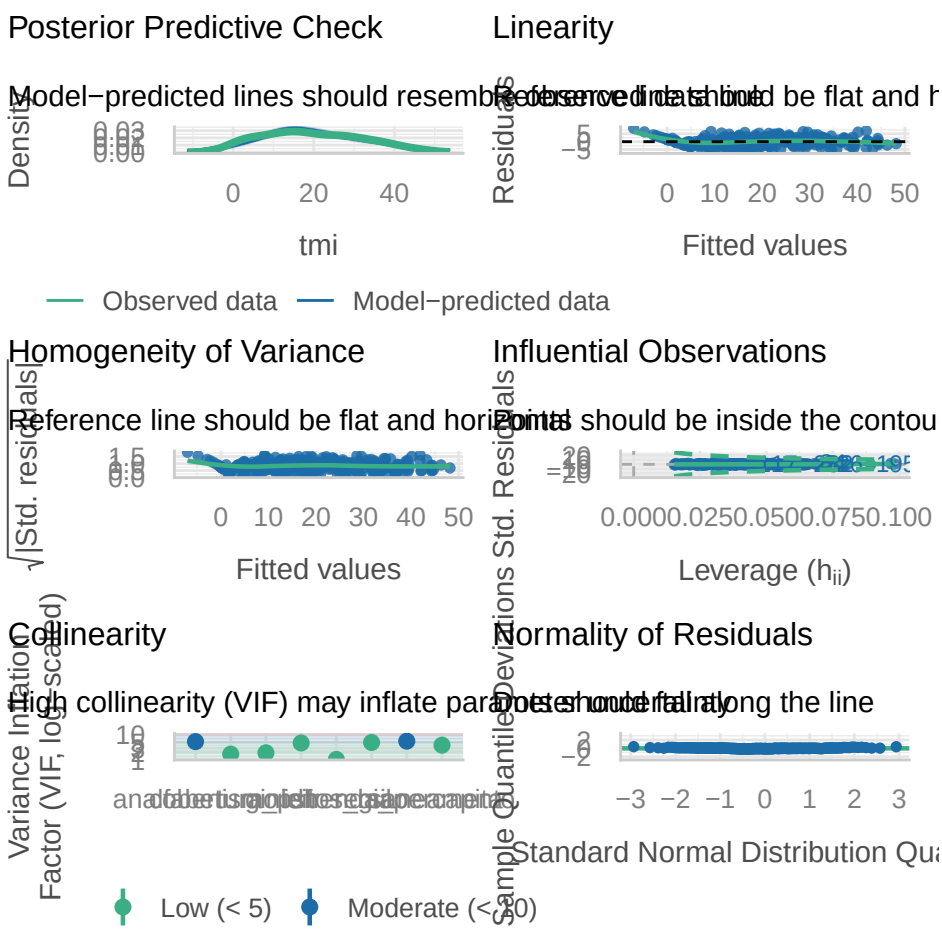

Previsões

Para realizar previsões com o modelo ajustado, é importante considerar valores das variáveis explicativas dentro dos intervalos observados na base de dados. Isso evita extrapolações que podem comprometer a confiabilidade das estimativas produzidas pelo modelo.

Assim, inicialmente apresenta-se um breve resumo das variáveis presentes na base de dados.

```
glimpse(dados)
```

```
Rows: 300
Columns: 11
$ id              <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16,~
```

```
$ tmi             <dbl> 9.99, 23.74, 1.50, 2.47, 16.11, 1.50, 35.44, 30.30, 10~
$ saneamento      <dbl> 74.4, 62.4, 82.4, 75.4, 68.3, 87.2, 48.0, 52.3, 72.7, ~
$ pib_percapita   <dbl> 25.09, 19.41, 36.21, 28.64, 21.22, 30.43, 11.36, 13.41~
$ cobertura_psf   <dbl> 73.4, 73.3, 72.8, 68.8, 78.1, 94.7, 58.8, 59.0, 66.3, ~
$ analfabetismo   <dbl> 7.8, 19.4, 2.7, 8.9, 13.5, 5.0, 22.2, 24.1, 7.7, 8.8, ~
$ gini            <dbl> 0.569, 0.588, 0.521, 0.492, 0.450, 0.506, 0.552, 0.596~
$ idh             <dbl> 0.950, 0.938, 0.950, 0.950, 0.950, 0.950, 0.802, 0.842~
$ renda_percapita <dbl> 1693, 1445, 2443, 2094, 1451, 2084, 753, 927, 1657, 20~
$ leitos_mil      <dbl> 0.84, 2.21, 2.76, 2.02, 1.60, 2.72, 0.89, 0.20, 0.20, ~
$ regiao          <fct> Sul, Nordeste, Sudeste, Sudeste, Nordeste, Sudeste, No~
```

```r
summary(dados)
```

```
       id              tmi           saneamento    pib_percapita
 Min.   :  1.00   Min.   : 1.500   Min.   :14.60   Min.   : 3.00
 1st Qu.: 75.75   1st Qu.: 9.863   1st Qu.:52.15   1st Qu.:11.68
 Median :150.50   Median :18.570   Median :63.80   Median :19.64
 Mean   :150.50   Mean   :19.890   Mean   :63.26   Mean   :20.11
 3rd Qu.:225.25   3rd Qu.:28.890   3rd Qu.:74.40   3rd Qu.:27.22
 Max.   :300.00   Max.   :48.820   Max.   :99.50   Max.   :53.87
                                   NA's   :5
 cobertura_psf   analfabetismo        gini             idh
 Min.   :32.70   Min.   : 0.00   Min.   :0.3630   Min.   :0.5980
 1st Qu.:56.08   1st Qu.: 6.80   1st Qu.:0.5020   1st Qu.:0.7945
 Median :64.95   Median :11.40   Median :0.5550   Median :0.9500
 Mean   :64.44   Mean   :11.95   Mean   :0.5515   Mean   :0.8684
 3rd Qu.:73.40   3rd Qu.:16.10   3rd Qu.:0.6022   3rd Qu.:0.9500
 Max.   :98.80   Max.   :30.40   Max.   :0.7340   Max.   :0.9500
 NA's   :4       NA's   :3
 renda_percapita    leitos_mil             regiao
 Min.   : 150.0   Min.   :0.200   Norte       :38
 1st Qu.: 797.2   1st Qu.:0.400   Nordeste    :81
 Median :1411.0   Median :0.940   Centro-Oeste:32
 Mean   :1419.6   Mean   :1.029   Sudeste     :99
 3rd Qu.:1947.2   3rd Qu.:1.460   Sul         :50
 Max.   :3710.0   Max.   :3.300
                  NA's   :3
```

A partir do resumo das variáveis observa-se que a taxa de mortalidade infantil (TMI) varia aproximadamente entre 1,5 e 48,8 óbitos por mil nascidos vivos, com média próxima de 19,89.

Entre as variáveis explicativas, o acesso ao saneamento varia aproximadamente entre 14,6% e 99,5%, enquanto a renda per capita apresenta valores entre 150 e 3710 unidades monetárias. Indicadores como analfabetismo, cobertura da atenção básica à saúde e índice de desenvolvimento humano também apresentam variação relevante entre as observações.

Esses intervalos permitem verificar que os valores utilizados nas previsões se encontram dentro de cenários plausíveis observados na base de dados.

Novas preditoras

Para ilustrar o processo de previsão utilizando o modelo ajustado, foram definidos três cenários hipotéticos contendo diferentes combinações de valores para as variáveis explicativas.

```
novas.preditoras <- data.frame(
  saneamento = c(40, 70, 90),
  cobertura_psf = c(50, 75, 90),
  analfabetismo = c(15, 8, 3),
  gini = c(0.55, 0.50, 0.45),
  idh = c(0.65, 0.75, 0.85),
  renda_percapita = c(600, 1200, 2500),
  leitos_mil = c(1.0, 2.0, 3.0),
  regiao = factor(
    c("Nordeste", "Centro-Oeste", "Sudeste"),
    levels = levels(dados$regiao)
  )
)
```

```
novas.preditoras %>% knitr::kable()
```

saneamento	cobertura_psf	analfabetismo	gini	idh	renda_percapita	leitos_mil	regiao
40	50	15	0.55	0.65	600	1	Nordeste
70	75	8	0.50	0.75	1200	2	Centro-Oeste
90	90	3	0.45	0.85	2500	3	Sudeste

Os cenários representam diferentes níveis de desenvolvimento socioeconômico.

O primeiro cenário apresenta menor acesso ao saneamento, maior taxa de analfabetismo e menor renda per capita, características associadas a contextos socioeconômicos menos favorecidos.

O segundo cenário apresenta condições intermediárias em relação aos indicadores analisados.

Já o terceiro cenário representa um contexto mais desenvolvido, com maior acesso ao saneamento, menor taxa de analfabetismo, maior renda per capita e maior disponibilidade de leitos hospitalares.

Intervalo de Confiança

Um **intervalo de confiança** captura a incerteza associada à estimativa do **valor médio esperado da variável resposta**, dado um conjunto específico de valores para as variáveis explicativas.

```
tab_IC <- predict(
  modelo_final,
  novas.preditoras,
  interval = "confidence"
)

tab_IC <- as.data.frame(tab_IC)

names(tab_IC) <- c(
  "Media_Prevista",
  "Limite_Inferior",
  "Limite_Superior"
)

tab_IC
```

```
  Media_Prevista Limite_Inferior Limite_Superior
1      35.962273       34.582894       37.341652
2      18.197336       16.798650       19.596021
3       1.104733       -0.633686        2.843153
```

Os resultados indicam que, no primeiro cenário, a TMI média esperada é aproximadamente 35,96 óbitos por mil nascidos vivos, com intervalo de confiança entre 34,58 e 37,34.

No segundo cenário, a TMI média estimada é aproximadamente 18,20, com intervalo entre 16,80 e 19,60.

No terceiro cenário, a TMI média estimada é aproximadamente 1,10, com intervalo entre -0,63 e 2,84.

Observa-se, portanto, uma redução consistente da taxa de mortalidade infantil à medida que os indicadores socioeconômicos apresentam melhora.

Intervalo de Predição

Um **intervalo de predição** captura a incerteza associada à previsão de **uma observação individual**, e não apenas do valor médio esperado.

```
tab_IP <- predict(
  modelo_final,
  novas.preditoras,
  interval = "prediction"
)

tab_IP <- as.data.frame(tab_IP, row.names = NULL)

names(tab_IP) <- c(
  "Valor_Previsto",
  "Limite_Inferior_Prev",
  "Limite_Superior_Prev"
)

tab_IP
```

```
  Valor_Previsto Limite_Inferior_Prev Limite_Superior_Prev
1      35.962273            30.444991            41.479554
2      18.197336            12.675196            23.719476
3       1.104733            -4.513079             6.722545
```

Os resultados indicam que, no primeiro cenário, a TMI prevista é aproximadamente 35,96, com intervalo de predição entre 30,44 e 41,48.

No segundo cenário, a previsão é aproximadamente 18,20, com intervalo entre 12,68 e 23,72.

No terceiro cenário, a previsão é aproximadamente 1,10, com intervalo entre -4,51 e 6,72.

Observa-se que os intervalos de predição são mais amplos que os intervalos de confiança, refletindo a variabilidade individual presente nos dados.

No terceiro cenário, o limite inferior do intervalo de predição assume valor negativo. Como a taxa de mortalidade infantil não pode assumir valores negativos na prática, esse resultado deve ser interpretado como uma indicação de que a mortalidade prevista é muito próxima de zero. Esse comportamento ocorre porque o modelo de regressão linear não impõe restrições ao intervalo de valores possíveis da variável resposta.

Comparação entre Intervalos

```r
tab_IC_e_IP <- cbind.data.frame(tab_IC, tab_IP)

tab_IC_e_IP %>% knitr::kable()
```

Media_Prevista	Limite_Inferior	Limite_Superior	Valor_Previsto	Limite_Inferior_Prev	Limite_Superior_Prev
35.962273	34.582894	37.341652	35.962273	30.444991	41.479554
18.197336	16.798650	19.596021	18.197336	12.675196	23.719476
1.104733	-0.633686	2.843153	1.104733	-4.513078	6.722545

A comparação entre os resultados mostra que os intervalos de predição são sistematicamente mais amplos do que os intervalos de confiança para os cenários analisados.

Por exemplo, no primeiro cenário o intervalo de confiança varia entre 34,58 e 37,34, enquanto o intervalo de predição se estende de aproximadamente 30,44 a 41,48.

Esse padrão se repete nos demais cenários, evidenciando que a incerteza associada à previsão de valores individuais é maior do que aquela relacionada à estimativa do valor médio esperado da variável resposta.

Esses resultados reforçam a importância de distinguir entre inferência sobre valores médios populacionais e previsão de observações individuais ao interpretar os resultados de modelos de regressão.

Conclusão

A análise realizada por meio do modelo de regressão linear permitiu identificar associações relevantes entre a taxa de mortalidade infantil e diferentes indicadores socioeconômicos e de infraestrutura. De forma geral, observou-se que melhores condições de desenvolvimento — como maior acesso ao saneamento, maior renda per capita, menor taxa de analfabetismo e melhores indicadores de saúde — estão associadas a menores níveis de mortalidade infantil.

As previsões realizadas para cenários hipotéticos reforçam esse padrão, evidenciando uma redução consistente na taxa de mortalidade infantil à medida que os indicadores socioeconômicos apresentam melhoria. Observa-se ainda que os intervalos de predição são mais amplos do que os intervalos de confiança, refletindo a maior incerteza associada à previsão de observações individuais.

Apesar de algumas limitações inerentes ao modelo de regressão linear — como a possibilidade de gerar valores previstos fora do intervalo plausível da variável resposta — os resultados

obtidos fornecem evidências consistentes sobre a relação entre condições socioeconômicas e mortalidade infantil.

De maneira geral, os resultados destacam a importância de políticas públicas voltadas à melhoria das condições de saneamento, educação, renda e acesso aos serviços de saúde como estratégias fundamentais para a redução da mortalidade infantil.